

卒業論文

VR コンテンツ体験時における生体情報に基づく感情推定フレームワーク

関西学院大学 理工学部 人間システム工学科

27020856 趙 聖化

2026年 3月

指導教員 井村 誠孝 教授

VR コンテンツ体験時における生体情報に基づく感情推定フレームワーク

趙 聖化

内容梗概

2010 年代以降, HMD の普及に伴い, ゲームや教育をはじめ様々な分野で没入型の VR(Virtual Reality) 体験が普及している. ユーザに提供される感情的な体験を適切に評価することが求められるが, 従来の評価はアンケートなど主観的手法に依存しており, リアルタイム性の欠如やバイアスの影響など多くの課題がある. 本研究の目的は, VR 体験におけるユーザの感情状態を客観的に評価する方法を探索することである.

本研究では, 生体センサと視線追跡を組み合わせた機械学習システムにより, VR 体験中の感情をリアルタイム推定するフレームワークを提案する. 具体的には, 皮膚電気活動 (EDA), 心電図 (ECG) から算出される心拍変動 (HRV), 筋電図 (EMG) などの生体信号と, コントローラ操作ログを同時に収集し, 多角的に解析する. マルチモーダルな情報を統合して恐怖・驚き・集中などの感情状態を識別することで, VR コンテンツの感情的効果をリアルタイムに評価可能なシステムを構築する.

提案手法の有効性を検証するため, Unity で実装した VR ホラーコンテンツを用いて予備的な参加者実験 (6 名, 計 8 セッション) を実施した. BITalino により EDA, ECG, EMG を 1 kHz で計測し, Unity イベントを TCP 通信で同期記録した結果, 探索・追跡フェーズで SCL および EMG の上昇傾向が確認された. 心拍系指標には個人差が大きく, 恐怖時のフリーズ反応が一部で観測された. また, 抽出特徴量に基づく機械学習により Phase 分類が可能であることを確認し (Random Forest, Accuracy 67.7%), 本フレームワークがリアルタイム感情推定に向けた基礎になり得ることを示した.

キーワード

アフェクティブコンピューティング, 生理心理学, マルチモーダルデータ融合, 生体信号, 行動情報, リアルタイム感情推定, バーチャルリアリティ

目次

第 1 章	序論	1
第 2 章	関連研究	3
2.1	生体信号に基づく感情推定	3
2.2	行動データに基づく注意および感情推定	3
2.3	マルチモーダル感情推定	4
2.4	感情実験設計およびラベリング手法	4
第 3 章	提案手法	7
3.1	ハードウェアインターフェースおよびセンサ構成	7
3.2	生体信号の前処理および数値変換モデル	7
3.2.1	心電図 (ECG) および筋電図 (EMG) の変換と前処理	7
3.2.2	皮膚電気活動 (EDA) の変換と前処理	8
3.3	特徴抽出	8
3.3.1	ECG 特徴	9
3.3.2	EMG 特徴	9
3.3.3	EDA 特徴	10
3.4	ユーザ入力およびイベントログの活用	10
3.4.1	ユーザ入力	10
3.4.2	システムイベント	10
3.4.3	統合解析	10
第 4 章	実装	11
4.1	開発環境およびシステム構成	11
4.2	ハードウェア構成	11
4.2.1	VR HMD	11
4.2.2	生体センシングシステム	11
4.2.3	センサチャンネル構成および装着位置	12
4.3	システムアーキテクチャおよびデータ同期	12
4.3.1	Unity-Python 間 TCP 同期設計	12
4.3.2	イベントログフォーマットと時間同期方式	13
4.4	Unity 側のシステム構成	13
4.4.1	BitalinoController.cs の設計	13
4.4.2	コンテンツ設計の基本コンセプト	14
4.4.3	4 段階実験フェーズ構成	14
4.4.3.1	Phase 0: ベースライン (Baseline)	14
4.4.3.2	Phase 1: 集中課題 (Focus / Go/No-Go Task)	15
4.4.3.3	Phase 2: 屋敷探索と予期不安 (Fear / Exploration)	15

4.4.3.4	Phase 3: ゾンビ追跡と驚き (Fear & Surprise / Pursuit)	16
第 5 章	実験	17
5.1	実験の目的	17
5.2	参加者	17
5.3	実験手順	17
5.4	実験環境	18
5.5	刺激シナリオ	18
5.6	データ収集	18
5.7	ラベリング	19
5.7.1	結果	19
第 6 章	実験結果	27
6.1	主観的感情評価分析	27
6.1.1	参加者別反応の類型化および特異事例の分析	27
6.2	客観的生体反応分析: フェーズ別統計および指標分析	27
6.2.1	皮膚電気活動 (EDA) 分析結果	28
6.2.2	心拍変動 (HRV) および心電図 (ECG) 分析結果	28
6.2.3	筋電図 (EMG) 分析結果	29
6.3	個人差分析および特異反応者の識別: 主観・客観連携の深層事例	29
6.3.1	特異な反応を示す参加者 (Subject E2)	29
6.3.2	認知失敗および低反応者 (Subject D)	30
6.3.3	無意識的緊張維持者 (Subject F)	30
6.4	機械学習による自動 Phase 分類	30
6.4.1	手法	30
6.4.2	分類結果	31
第 7 章	考察	35
7.1	実験結果の解釈および生体信号の反応	35
7.2	参加者別特異反応とすくみ (Freezing) 現象	35
7.3	機械学習基盤フェーズ分類の意義および特徴量分析	36
7.4	リアルタイム感情認識システム高度化のための展望	36
7.5	技術的限界および改善方向	36
第 8 章	結論	39
	謝辞	41
	参考文献	43
	研究業績	45

表目次

3.1 抽出された生理学的特徴量の一覧	8
4.1 Unity-Python 間 TCP コマンド一覧	13
5.1 実験フェーズの構成と誘導される感情状態	18
5.2 収集データの概要	18
5.3 主要イベントマーカー	21
5.4 実験後アンケート回答結果の要約	22
5.5 事後アンケート詳細結果 (7 点 Likert 尺度, 平均 $\pm$ SD)	22
5.6 全参加者の Phase 別生体反応統計量 (6 名, 8 セッション, Mean $\pm$ SD)	23
6.1 全参加者のフェーズ別 EDA (SCL) 統計値 (Mean $\pm$ SD)	28
6.2 全参加者のフェーズ別 ECG/HRV 主要統計値 (Mean $\pm$ SD)	28
6.3 ベースライン正規化後のフェーズ別 ECG/HRV 変化率 (% , Mean $\pm$ SD)	29
6.4 全参加者のフェーズ別 EMG 主要統計値 (Mean $\pm$ SD)	29
6.5 機械学習に使用した特徴量	30
6.6 Phase 分類モデルの性能比較 (LOSO 交差検証)	31

図目次

4.1 各生体センサの装着位置	12
4.2 提案システムのデータフローおよび TCP 同期メカニズム	14
4.3 Phase 0: ベースライン測定 (安定)	15
4.4 Phase 1: 集中課題 (Go/No-Go Task)	15
4.5 Phase 2: 屋敷探索と予期不安	16
4.6 Phase 3: ゾンビ追跡と驚き	16
5.1 連続生体信号記録 (Subject E2). 上から EMG エンベロープ,EDA(SCL),ECG フィルタ済み信号. 各 Phase は背景色で区別される (Phase 0: 青, Phase 1: 橙, Phase 2: 赤, Phase 3: 紫).	19
5.2 Subject E2 の Phase 別取得データ. 各列は Phase 0–3 を, 各行は EMG,EDA,ECG を示す. 赤点線は Phase 内の平均値.	20
5.3 Subject E2 の Phase 別前処理済み信号と特徴量. 第 1 行: EMG エンベロープ, 第 2 行: EDA(SCL), 第 3 行: ECG(R-peak 検出), 第 4 行: 主要特徴量.	21
5.4 イベントマーカと分析ウィンドウの定義. 各イベント発生時点 (t_0) を中心に前後 2.5 秒 (計 5 秒 間) のウィンドウを設定.	22
5.5 Phase 別平均生体反応 (6 名,8 セッション,Mean $\pm$ SD)	23
5.6 Phase 別生体反応の箱ひげ図 (6 名,8 セッション).	24
5.7 参加者別 Phase 変動	24
5.8 参加者 $\times$ Phase ヒートマップ	25
6.1 Phase 分類モデルの性能比較	31
6.2 各モデルの正規化混同行列	32
6.3 Random Forest モデルの特徴量重要度	33
6.4 参加者別 Phase 分類精度	33

第1章 序論

VR(Virtual Reality) 技術が急速に発展し、エンタテインメント、教育、医療など様々な分野で没入型の VR 体験が提供されるようになっていく。VR コンテンツではユーザに恐怖や興奮、感動といった強い感情的体験を与えることが可能であり、感情を引き出す効果を高めるための工夫が重ねられている。一方で、VR 体験がユーザに与える感情的影響や体験の質を客観的に評価することは困難である。特に、VR コンテンツ制作者が意図する感情体験がユーザに確実に伝わっているかを検証することは重要な課題であるが、適切な評価手法は確立されていないのが現状である。

VR 体験の効果やユーザの感情反応を評価する際には、アンケートやインタビューなど体験後の主観評価に頼ることが一般的である。しかし、主観的な評価には回答者のバイアスや記憶の曖昧さが影響する上、体験中の瞬時の感情変化を捉えることはできない。また、評価のために体験を中断してその場で質問を行うことは没入感の阻害につながるため、リアルタイムでユーザの感情状態を検出することは困難である。

上述の問題に対し、工学的アプローチとして、ユーザの生体信号や行動データを用いて感情状態を客観的に推定する方法が注目されている。人間の感情は自律神経系の反応として生理指標に現れることが知られており、例えば皮膚電気活動 (Electrodermal Activity; EDA) は交感神経の活動度を反映する指標で、恐怖や驚きにより覚醒度が高まるとき顕著な上昇を示す。心電図 (Electrocardiogram; ECG) から得られる心拍変動 (Heart Rate Variability; HRV) は副交感神経と交感神経のバランスを示す指標であり、一般にストレス下では HRV は低下する傾向にある [1, 2]。さらに、筋電図 (Electromyography; EMG) は筋肉の活動を測定する手法で、驚いた際の瞬発的な筋反応や持続的な筋緊張度の変化を捉えることができる。また、コントローラの操作頻度や動作の変化も感情反応の指標となり得る。感情を反映した行動の例として、突発的な驚き刺激に対して咄嗟に操作が乱れる、あるいは強い恐怖に直面して一時的に操作が止まる「すくみ (Freezing)」といった現象が挙げられる。以上のように、生体情報と行動情報の双方をマルチモーダルに取得・分析することで、単一の指標では捉えきれないユーザの内面的な感情変化をより正確に推定できると期待される。

本研究では、マルチモーダルな生体・行動情報の分析というアプローチに基づき、VR 体験中のユーザの感情状態をリアルタイムに推定するフレームワークを提案する。本研究の目的は、生体情報と行動データの統合解析によって VR コンテンツの感情的効果を客観的に評価する手法を確立することである。具体的には、EDA、HRV、EMG といった生体センサ情報と、コントローラの操作ログを同時に取得し、収集したデータを VR コンテンツのイベントと同期させることで、恐怖・驚き・集中といった感情状態を識別するためのデータセットを構築する。構築したデータを用いて機械学習モデルを訓練し、マルチモーダルな特徴量に基づくリアルタイム感情推定を実現することを目指す。

本論文の構成は以下の通りである。第2章では、生体信号に基づく感情推定と VR 環境における行動分析に関する関連研究を検討する。第3章では、本研究で提案するマルチモーダル感情推定フレームワークの設計と生体信号処理アルゴリズムについて説明する。第4章では、システムのハードウェアおよびソフトウェアの実装詳細を記述し、第5章では、提案システムの有効性を検証するための参加者実験の設計および手順について論じる。第6章では、実験を通じて得られた主観的および客観的データの分析結果と機械学習モデルの性能を提示する。第7章では、実験結果の生理学的意義と技術的限界および今後の発展方向について考察し、最後に第8章で本研究の結論を述べる。

第2章 関連研究

本章では、本研究に関連する先行研究および基礎知識について述べる。まず生体信号を用いた感情推定手法について概説し、次に行動データに基づく注意および感情推定手法を紹介する。続いて、複数のモダリティを統合するマルチモーダル感情推定の最新動向を考察し、最後に感情実験の設計およびラベリング手法について説明する。

2.1 生体信号に基づく感情推定

生体信号に基づく感情推定は、顔表情や音声のような外見の手がかりに依存する手法と比較して、主観的な操作や偽装が困難であり、自律神経系および中枢神経系の反応を直接捉えることができるという点で客観性と再現性に優れている [1]。

顔表情や音声などの物理的信号は社会的な文脈に応じて意図的に抑制・加工が可能であるが、心電図、皮膚電気活動、筋電図などは自律神経系によって不随意に制御されるため、ユーザの本質的な内的状態を高い信頼性で反映する [3]。

特に VR 環境では HMD の装着により顔領域の可視性が制限され、伝統的な表情認識手法の適用が困難であるが、心電図、皮膚電気活動、筋電図、脳波などの信号は、ユーザの没入感を阻害することなく同時に収集することが容易である [1, 4]。

収集された生体データは、VR コンテンツの設計において、どの場面で肯定的あるいは否定的な情動反応が生じたかを特定する客観的フィードバックや、ユーザの状態に応じて刺激強度や提示様式を調整する適応型 VR の基礎データとして活用できる [1, 2]。ただし、生体信号は感情のみに特異的な信号ではなく、運動・発話・姿勢変化や VR 酔いなどの要因によっても変動するため、実験設計段階での統制と、アーティファクト除去、ベースライン補正などの信号処理が不可欠である [1]。

深層学習技術の発展は、生体信号の複雑な非線形パターンの学習に寄与している。Dar らは、14 チャンネル EEG の不規則な構造的特性を反映するために、EEG 信号を 81×128 サイズの 2 次元画像にマッピングして空間的特徴を抽出する 2D-CNN アーキテクチャを提案している [5]。ECG と GSR 信号に対しては、1D-CNN と LSTM を結合して信号の局所的な時間的特徴と長期的な依存関係を同時に学習することで、感情状態を精密に識別できることを実証している。

自律神経系指標の中で、心拍変動と皮膚電気活動は情動的覚醒を反映する核心的な指標として広く活用されている。一般に恐怖のような高覚醒刺激時には交感神経系が活性化し、心拍数 (HR) が上昇し、HRV 指標 (RMSSD など) が低下する傾向を示す。Hinkle らは VR 環境において EDA 信号のみを用いて高覚醒/低覚醒状態を区別し、SVM および k-NN 分類器を通じて最大 89 % の認識精度を達成している [6]。

2.2 行動データに基づく注意および感情推定

ユーザの行動ログは生理的反応と密接に関連しており、注意の集中度や情動状態を間接的に推定する重要な手がかりとなる。VR 環境では、視線追跡、頭部および身体の動き、コントローラ操作ログなどが主要なデー

タソースとして活用される。その中でも視線追跡データは HMD 内蔵のアイトラッカーを通じて取得可能であり、注視対象や探索パターンを通じてユーザの関心度や脅威回避行動を分析することに寄与する。

また、コントローラ操作頻度や反応遅延時間などの能動的インタラクションログは、没入度や恐怖反応を推論するツールとして使用される。恐怖状況において、ユーザが逃避のために操作を高頻度で行ったり、逆に極度の恐怖によって身体や操作が一時的に停止する「すくみ (Freeze)」現象が観察されることがある [7]。このようなすくみ反応は脅威に対する人間の本能的な防御機構であり、VR 内でも頭部や手の移動速度が瞬間的に低下する時系列パターンを通じて捕捉可能である [8]。行動パターンをイベントのタイムラインと同期させて分析することで、ユーザの注意の方向と刺激に対する多面的な情動反応を把握することができる。

2.3 マルチモーダル感情推定

マルチモーダル感情推定は、異なる 2 つ以上のデータソースを結合して対象の状態を推定する方法であり、感情認識分野でも複数の信号を融合することで性能向上を図る研究が増加している。単一の生体信号や単一の行動指標だけでは得られる情報に限界があるが、複数の指標を相互補完的に結合することで、より正確で堅牢な感情分類が可能になる。

生体信号を用いた感情推定研究は活発に行われており、複数の生体信号を組み合わせることで単一センサよりも推定精度が向上することが報告されている [1, 9]。特に VR 環境下では、脳波 (EEG) と心拍変動を用いて感情価と覚醒度を推定する研究 [10] や、ユーザの心拍数反応に応じてゲームの難易度をリアルタイムかつ動的に調整する試み [2] などがあり、生体情報とコンテンツ間の密接な相互作用である「アフェクティブ・ループ」の実現可能性を裏付けている。

このようなマルチモーダルアプローチの優位性は、大規模データセットを用いた実験を通じて証明されている。Dar らは EEG, ECG, GSR 信号を統合し、AMIGOS データセットで 99.0 %, DREAMER データセットで 90.8 % の感情分類精度を達成している [5]。この精度は単一モダリティを使用した場合よりも飛躍的に高い数値であり、異なる生体信号が感情の多様な側面を相互補完的に説明していることを示している [5]。

Arslan らは、ECG と GSR 信号に統計的特徴選択手法を結合して 97.78 % の高い精度を記録している [11]。彼らは興奮、幸福、不安、平穏、悲しみの 5 つの感情状態を分類しているが、一部の感情間の境界が曖昧であり、新規ユーザへの一般化に限界があることも報告している。しかし、多くの研究が特定の条件下での感情分類に留まっており、多様な VR 体験や個人ごとの生理的偏差を包括できる汎用的なフレームワークは未だ確立されていないのが実情である。

本研究はこのような限界を克服するため、生体信号 (EDA, ECG, EMG) と行動データを統合し、リアルタイムのイベント同期とベースライン補正を適用した汎用的な感情推定モデルの構築を目指す。

2.4 感情実験設計およびラベリング手法

感情状態を科学的に研究するためには、信頼性の高い感情誘発シナリオの設計と正確な正解ラベルの確保が必須である。VR は従来のメディアよりも強力な没入感を提供し、恐怖や驚きなどの反応を誘発するのに最適化されている [4]。恐怖研究では、ジャンプスケア要素や照明、音などを活用した環境デザインが主に用いられる [12]。Radiah らは、バーチャル環境のレイアウト、色彩、音、装飾、天候という 5 つの次元のデザイン空間を提案し、各次元のデザインをリアルタイムで制御してユーザの感情を誘発および評価できる「EmotionEditor」ツールボックスを開発している [13]。このようなツールは実験設計の体系性を高め、研究

者が意図した感情状態をより精密に誘導できるようにする。

ラベリング手法は大きく分けて、客観的イベントベースのラベリングと主観的自己報告ラベリングに区別される。イベントベースの方式は特定の刺激発生時点を基準にラベルを割り当てるためデータ同期が容易である反面、自己報告方式は SAM(Self-Assessment Manikin) などの尺度を通じて実際のユーザが感じた感情の強度を数値化する [1, 4]。本研究では主要イベント直後に事後アンケートを実施して獲得した感情強度ラベルを生体データと対照分析することで、データセットの信頼性を確保する。

第3章 提案手法

本研究では,VR 環境における没入感を阻害することなく,ユーザの内面的な感情状態を客観的に把握するためのリアルタイム感情推定フレームワークを提案する. 本フレームワークは,高精度生体信号センサと VR HMD (Head Mounted Display) の行動ログを統合し,感情状態を多角的に分析する [1].

3.1 ハードウェアインターフェースおよびセンサ構成

ユーザの身体反応測定のために以下のようなセンサを使用する.

- EMG : 右腕に REF 電極を電氣的に中立的な骨部位に装着し, IN+および IN- 電極を筋繊維方向に整列されるように筋腹の上に 20 mm 間隔で装着して,筋肉の電氣的活動および緊張度を測定する.
- EDA : 右手のひらに電極を装着し,皮膚伝導度の変化を測定する [6].
- ECG : REF 電極を腸骨稜に装着し, IN+および IN- 電極を胸部に装着して,心電図信号を測定する.

センサ装着後には電極接触安定化のために必要な手順を実施する.

3.2 生体信号の前処理および数値変換モデル

BITalino センサから収集される取得データを物理的意味を持つ単位に変換するため,以下のような変換を適用する. 生体信号取得システムの動作電圧を V_{CC} ,ADC 解像度を n ビットとする.

3.2.1 心電図 (ECG) および筋電図 (EMG) の変換と前処理

心電図および筋電図信号は,AD 変換を経て得られたデータに対して,以下の変換を行い ECG(V), EMG(mV) を得る.

$$\text{ECG} = \left(\frac{\text{ADC}}{2^n - 1} - 0.5 \right) \times \frac{V_{CC}}{G_{\text{ECG}}}$$
$$\text{EMG} = \left(\frac{\text{ADC}}{2^n} - 0.5 \right) \times V_{CC} \times \frac{1000}{G_{\text{EMG}}}$$

変換された信号は以下のように前処理される.

- ECG: 0.5–40 Hz 帯域通過フィルタを適用した後,R-peak 検出を実行する.
- EMG: 20–450 Hz 帯域通過フィルタリング後,整流および包絡線抽出を通じて筋肉緊張度を算出する.

表 3.1 抽出された生理学的特徴量の一覧

信号	特徴量	単位	生理学的意義
ECG	心拍数	bpm	全般的な覚醒水準
	RMSSD	ms	副交感神経活動
	SDNN	ms	全体的 HRV (交感+副交感)
	pNN50	%	副交感神経活動比率
	LF パワー	ms ²	交感+副交感神経活動
	HF パワー	ms ²	副交感神経活動
	LF/HF 比	-	自律神経バランス (ストレス指標)
EMG	平均電圧	μV	筋緊張の基礎水準
	最大電圧	μV	筋活動のピーク強度
	RMS 電圧	μV	筋活動エネルギー
EDA	平均 SCL	μS	基礎的覚醒水準
	SCR パルス数	回	刺激に対する反応頻度

3.2.2 皮膚電気活動 (EDA) の変換と前処理

皮膚導電率は, 以下の関数を用いてマイクロジーメンス (μS) 単位に変換される.

$$\text{EDA} = \frac{\text{ADC}}{2^n} \times \frac{V_{\text{CC}}}{0.132}$$

本公式の分母の 0.132 は EDA センサの回路設計に基づく伝達関数の定数である. EDA 信号は 0.5 Hz 低域通過フィルタ (LPF) を適用した後, 緩やかに変化する SCL (Tonic) 成分と特定の刺激による急激な変化を表す SCR (Phasic) 成分に分解して処理する.

SCL (Skin Conductance Level, Tonic) とは, 皮膚コンダクタンスの基底レベルを意味する長期的なトニック反応 (Tonic level) である. SCL は背景覚醒レベルを反映し, 心理的ストレスや環境的要因によって数十秒から数分にわたって緩やかに変化する特性を持つ. 一般的に一定区間の皮膚コンダクタンス信号の平均または中央値として算出され, 自律神経系緊張度の基底状態を表す指標として活用される.

SCR (Skin Conductance Response, Phasic) とは, 特定のイベントや刺激に対する反応として現れる短期的かつ急激な位相性反応 (Phasic response) である. 刺激直後約 1–5 秒以内にコンダクタンスが急激に増加し, 該当刺激に対する神経生理学的覚醒度を直接的に反映する. SCR 振幅 (SCR_{amp}) は反応の最大値 (SC_{peak}) と反応開始時点のレベル (SC_{onset}) の差として定義され, 以下のように算出する.

$$\text{SCR}_{\text{amp}} = \text{SC}_{\text{peak}} - \text{SC}_{\text{onset}}$$

3.3 特徴抽出

前処理された各信号から感情推定に有効な時系列特徴量を抽出する. 本研究では, 感情状態を反映する生理学的指標として以下の特徴量を算出する [3].

3.3.1 ECG 特徴

心電図から心拍数および心拍変動指標を抽出し、自律神経系反応を分析する。指標は時間領域と周波数領域に分けられる。

時間領域の HRV 指標として、以下の統計量を算出する。

- 平均心拍数: 1 分間あたりの心拍数 (bpm)
- RMSSD: 連続する RR 間隔の差分の二乗平均平方根であり、副交感神経の活動指標として広く用いられる。

$$\text{RMSSD} = \sqrt{\frac{1}{N-1} \sum_{i=1}^{N-1} (RR_{i+1} - RR_i)^2}$$

- SDNN: NN 間隔の標準偏差であり、交感・副交感神経の両方を含む全体的な HRV 指標である。

$$\text{SDNN} = \sqrt{\frac{1}{N} \sum_{i=1}^N (RR_i - \overline{RR})^2}$$

- pNN50: 連続する RR 間隔の差が 50 ms 以上である割合 (%) であり、副交感神経活動を反映する。

また、周波数領域の HRV 指標として、RR 間隔時系列を FFT により周波数領域に変換し、パワースペクトル密度 (Power Spectral Density: PSD) を算出する [14]。

PSD は、信号のパワー (分散) が周波数ごとにどのように分布しているかを表す関数である。離散信号である RR 間隔時系列の離散フーリエ変換 (DFT) を $X(f)$ とすると、PSD は一般に以下のように定義される。

$$\text{PSD}(f) = \frac{1}{N} |X(f)|^2$$

ここで、 N はデータ点数、 f は周波数を表す。この PSD を特定の周波数帯域で積分 (面積計算) することで、以下のような各指標のパワー値が算出される。

- LF パワー (0.04–0.15 Hz): 交感神経と副交感神経の両方の活動を反映
- HF パワー (0.15–0.40 Hz): 副交感神経活動 (呼吸性洞性不整脈) を反映
- LF/HF 比: 自律神経系バランス指標。値が高いほどストレス状態を示す

$$\text{LF/HF} = \frac{\int_{0.04}^{0.15} \text{PSD}(f) df}{\int_{0.15}^{0.40} \text{PSD}(f) df}$$

3.3.2 EMG 特徴

筋肉活動の強度を定量化するため、以下の特徴量を算出する。

- 平均電圧, 最大電圧 (μV)
- RMS 電圧: 筋活動の全体的なエネルギー量

$$\text{RMS} = \sqrt{\frac{1}{N} \sum_{i=1}^N x_i^2}$$

3.3.3 EDA 特徴

皮膚電気活動 (EDA) からは, 以下の特徴量を抽出して分析に用いる.

- 平均 SCL (μS): 基礎的な覚醒水準を示す皮膚電気伝導度の平均値
- SCR パルス数: 刺激に対する一過性反応の回数 [6]

3.4 ユーザ入力およびイベントログの活用

本提案手法では, 生体信号のみならず, VR 環境内でのユーザの行動 (入力) とシステム側で発生するイベントを統合的に解析することで, 感情推定の精度と解釈性を向上させる.

3.4.1 ユーザ入力

VR コントローラの操作ログと HMD のトラッキングデータを取得し, ユーザの能動的な行動を分析する.

- トリガー・ボタン入力: (後述する VR コンテンツにおける)Phase 1 での射撃課題 (Right Trigger) や, Phase 2での懐中電灯操作およびアイテム収集など, 意図的なインタラクションを記録する.
- トラッキングデータ: HMD およびコントローラの 6 自由度 (6DoF) データを記録する. トラッキングデータにより, 驚き刺激に対する瞬発的な回避動作や, 強い恐怖に直面した際の身体硬直 (Freezing) 反応などの行動的特徴を抽出することが可能となる. 特に Phase 3 では, プレイヤーの視線ベクトルとゾンビの位置関係から「直視」イベントを判定するために活用される.

3.4.2 システムイベント

VR コンテンツの進行状況や特定の刺激発生タイミングをイベントマーカーとして記録し, 生体信号の文脈として活用する.

- フェーズ遷移: 実験フェーズの切り替わりを記録し, ベースラインとの比較やフェーズごとの状態推定に使用する.
- タスク・イベント: Phase 1 の試行開始, Phase 2 のアイテム獲得, Phase 3 のゾンビ接近など, 感情変化のトリガーとなる瞬間を特定する.
- 環境変化: ドアの開閉, BGM の切り替えタイミングなどを記録し, 環境要因によるストレス変化を分析する.

3.4.3 統合解析

収集された生体信号 (EDA, ECG, EMG) とイベントログは, 共通のタイムスタンプおよびサンプルインデックスを用いて厳密に同期される. タイムスタンプによる同期により, 「ゾンビが接近した瞬間」や「アイテムを発見した瞬間」など, 特定の感情生起イベント直後の生理反応 (SCR のピーク, 心拍数の急上昇など) をセグメンテーションし, イベントと生体反応の因果関係を明確にした分析が可能となる.

第4章 実装

本章では、提案したシステムの実装方法を具体的に記述する。使用したハードウェアとソフトウェア環境を紹介し、各モジュールの具体的な実装方法を説明する。

4.1 開発環境およびシステム構成

本研究における VR コンテンツの実装および実行環境は Unity を用いており、HMD には Meta Quest Pro を使用した。言語およびシステム構成は以下の通りである。

- Unity 側: VR コンテンツ/イベント発生, TCP クライアント
- Python 側: TCP サーバ + BITalino データ収集/ロギングモジュール

Unity (C#) と Python 間の通信は TCP ソケット通信で構成し、Unity プロジェクト内の主要通信スクリプトは `BitalinoController.cs`、Python 側は `bitalino_unity_server.py` として役割を分離した。

4.2 ハードウェア構成

本実験システムを構成するハードウェア機器として、映像提示のための VR HMD と、生体信号取得のためのセンサシステムについて述べる。

4.2.1 VR HMD

本実験では、Meta Quest Pro をヘッドマウントディスプレイとして使用した。参加者は両手のコントローラを用いて VR 空間内を移動し、特定のインタラクション（ドアの開閉、アイテム取得など）を行うことで、システムへの入力と行動データの収集を行った。

4.2.2 生体センシングシステム

参加者の生理的反応を測定するために BITalino (r)evolution ボードを使用した。BITalino デバイスは EMG、ECG、EDA などのアナログ生体信号を測定し、測定した信号を 10-bit ADC を通じてデジタル化して出力する。データのサンプリング周波数は 1000 Hz に設定した。

収集された各センサのデジタル値は専用センサデータシートに提示された変換公式を通じて物理的単位に換算される。本研究では、第 3 章の提案手法で示した数式を用いて各信号の変換処理を行う。具体的なシステムパラメータは以下の通りである。

- 動作電圧 (V_{CC}): 3.3 V
- ADC 解像度 (n): 10-bit (0 ~ 1023)
- センサ別ゲイン定数: BITalino (r)evolution センサの製造元 (PLUX Biosignals) 公式データシートに定義された固有値を適用した。




図 4.1 各生体センサの装着位置

- 心電図 (ECG): $G_{\text{ECG}} = 1100$
- 筋電図 (EMG): $G_{\text{EMG}} = 1009$

4.2.3 センサチャンネル構成および装着位置

各センサの装着位置および構成は、3.2 節で提案した手法に準拠する。具体的なセンサの装着状況を図 4.1 に示す。

4.3 システムアーキテクチャおよびデータ同期

本システムは、Unity 2022.3 LTS による VR 環境と Python 分析サーバーを有機的に統合したマルチモーダルデータ収集プラットフォームとして構築した。両者間のデータ連携には非同期 TCP/IP ソケット通信を用いている。各モジュールの役割とデータフローを図 4.2 に示す。

4.3.1 Unity–Python 間 TCP 同期設計

本システムは、ユーザの感情を誘発する VR コンテンツの進行状況に合わせて、生体信号データにイベントラベルを付与するように設計されている。このデータ連携を実現するために、Unity から Python サーバへイベントタイミングを伝達し、BITalino のサンプルデータと結合する構造を採用している。

Unity 側では `BitalinoController.cs` で `TcpClient` を用いてローカルの Python サーバに接続し、Phase 開始/終了および主要イベント発生時に文字列コマンドを送信する。送信方式は `writer.WriteLine(cmd)` 形式で改行ベースのメッセージ境界を使用して実装した。

表 4.1 に、Unity から Python サーバへ送信される TCP コマンドの一覧を示す。上記のコマンドを介して、Unity と Python は双方向的なデータ連携を実現している。`BitalinoController.cs` は実験全体で共通して使用される通信モジュールであるため、シングルトンおよび `DontDestroyOnLoad` 形式で維持されるように設計し、シーン転換時にも接続状態を保存する。

Python 側は TCP サーバとして動作し、Unity から受信したコマンドをイベントログとして記録すると同時に、BITalino 装置から生体信号サンプルを持続的に読み取り保存する。特に START 受信時に BITalino 接続および測定を開始し、以降の Unity コマンドをイベント CSV として時系列順に記録する。STOP または EXPERIMENT_END 受信時には測定を終了し、収集したデータをファイルに保存する。

表 4.1 Unity-Python 間 TCP コマンド一覧

Phase	コマンド	説明
システム制御	START	BITalino 接続開始・測定開始
	STOP	測定終了・データ保存
	EXPERIMENT_END	実験全体の終了
Phase 0	PHASE0_BASELINE_START	ベースライン測定開始
	PHASE0_BASELINE_END	ベースライン測定終了
Phase 1	PHASE1_TASK_START	認知課題 Phase 開始
	P1_TRIAL_ONSET_GO	各試行の開始タイミング
Phase 2	PHASE2_SCENE_START	悲しみ誘発シーン開始
	P2_PIECE_1	シーンイベント 1 発生
	P2_PIECE_2	シーンイベント 2 発生
	P2_PIECE_3	シーンイベント 3 発生
	P2_PIECE_4	シーンイベント 4 発生
Phase 3	PHASE3_START	恐怖誘発シーン開始
	P3_ZOMBIE_NEAR_1	ゾンビ接近イベント 1
	P3_ZOMBIE_NEAR_2	ゾンビ接近イベント 2
	P3_ZOMBIE_LOOK_1	ゾンビ注視イベント
	DOOR_OPEN	ドア開放イベント

4.3.2 イベントログフォーマットと時間同期方式

イベントログは以下のような CSV フォーマットで記録する。

```
unix_time, sample_index, label
```

ここで `sample_index` は BITalino 側のサンプルインデックスで、生理データと Unity イベントを同一時間軸にマッピングするキーとして使用する。Unity イベントは「いつ発生したか」をコマンドで伝達し、Python は該当コマンドを受信した時点の `sample_index` を共に記録することで、以後の分析段階で生体信号 (EDA/ECG/EMG) とイベント (ジャンプスケア/ゾンビ接近/ドア開放など) の対応付けが可能になる。

4.4 Unity 側のシステム構成

Unity プロジェクトでは実験の各 Phase (Phase 0 ~ Phase 3) に対応するマネージャスクリプト (例: `Phase0Manager`, `Phase1Manager`, `Phase23Manager` など) を作成し、イベント発生時の処理を制御した。

4.4.1 BitalinoController.cs の設計

Unity 環境では `BitalinoController.cs` が通信操作を行う。本スクリプトはシングルトンパターンで実装され、シーン転換が発生しても破棄されない特性を持つ。

- TCP 接続確立: 実験開始時、Python サーバへの接続を試みる。




図 4.2 提案システムのデータフローおよび TCP 同期メカニズム

- イベントマーカ送信: VR 空間で発生する全ての意味的イベント (Phase 転換, アイテム獲得, 敵接近など) を文字列コマンドで構成し, `writer.WriteLine(cmd)` を通じて即時送信する. ネットワーク遅延を最小化するため, 非同期スレッドで処理される.

4.4.2 コンテンツ設計の基本コンセプト

本研究で制作した VR コンテンツは, 特定の感情状態 (集中, 恐怖, 驚き) を意図的かつ自然に誘発するように設計されたホラーアドベンチャーゲームである. コンテンツは Unity で開発され, 暗い屋敷を探索しながらアイテムを収集する探索型ホラー形式を導入した. この形式はプレイヤーの自発的行動 (探索) と, システム側の予期せぬ介入 (ジャンプスケア) を結合することで, 多様な感情をカバーするのに適している.

4.4.3 4 段階実験フェーズ構成

本研究で制作した VR コンテンツは探索・追跡型 VR ホラーゲームであり, 感情状態を段階的に誘導するために Phase 0-3 の順次構造で設計した. また, 各フェーズおよびイベントの状況に応じて異なる BGM および効果音を使用した. Phase 2 の探索パートでは不気味で静かな環境音を再生し緊張感を高める. アイテム獲得時には通知音を鳴らす. Phase 3 でゾンビが登場し追跡が始まると, テンポの速い緊迫した追跡用 BGM に切り替えることで, 聴覚的刺激による恐怖と焦燥感を増幅させる. 実験は生体信号の変化を正確に測定するため, 以下の 4 つのフェーズに分割して進行する.

4.4.3.1 Phase 0: ベースライン (Baseline)

Phase 0 は, 参加者の平常時の生体信号を測定し, 基準値を確立するためのフェーズである.

- 目的: 参加者の安静時生理指標の基準値を確保する.
- 環境: 刺激のない静的な環境で安定した状態を 60 秒間維持し, 基準生理値を確保する (図 4.3).

この期間のデータは, 個人差の大きい EDA・HRV の変化量を正規化するための基準として使用される.






図 4.3 Phase 0: ベースライン測定 (安定)



(a) Go 課題 (緑のボール・射撃)



(b) No-Go 課題 (赤のボール・待機)

図 4.4 Phase 1: 集中課題 (Go/No-Go Task)

4.4.3.2 Phase 1: 集中課題 (Focus / Go/No-Go Task)

Phase 1 は、恐怖刺激のない環境下で認知課題を行い、集中状態における生体反応を取得するフェーズである。

- 目的: 恐怖・驚きの影響がない状態で、純粋に集中している状態の生理データを取得する。
- 環境: 明るいラボ (実験室) 風のトレーニングルーム。
- メカニズム: 恐怖要素を排除した反応抑制課題 (Go/No-Go) を実施させる。正面に現れる緑の球体 (Go) には射撃 (トリガー) 反応、赤の球体 (No-Go) には反応しない抑制課題 (図 4.4)。約 30 回の試行がランダム間隔で繰り返される。
- ラベリング: P1_TRIAL_ONSET_GO などのマーカーで課題遂行中の認知負荷と集中状態を記録する。

4.4.3.3 Phase 2: 屋敷探索と予期不安 (Fear / Exploration)

Phase 2 は、視覚的制限と環境音により予期不安を煽りながら探索を行うフェーズである。

- 目的: 視野制限と音響演出で持続的恐怖 (不安) を誘発する。
- 環境: 暗い屋敷内部 (図 4.5 (a))。
- 制約: 光源は左手トリガーを押している間のみ点灯する懐中電灯に制限される。
- 課題: 屋敷内に隠された 4 つのアイテムを収集する (図 4.5 (b))。収集個数に応じて環境が段階的に変化する。不確実性と緊張を高め、環境音、効果音、照明などの演出を通じて恐怖・警戒状態を誘導する。
 - 1-2 個目: 微細な環境音の変化。



(a) 屋敷内部の暗い環境



(b) アイテム探索 (アイテム収集)

図 4.5 Phase 2: 屋敷探索と予期不安



(a) 潜んでいるゾンビの発見



(b) ゾンビによる追跡 (恐怖・驚き)

図 4.6 Phase 3: ゾンビ追跡と驚き

- 3 個目: 遠くから聞こえる不吉な悲鳴/物体落下音 (ジャンプスケア前兆).
- 4 個目: 収集完了と同時に Phase 3 強制移動マーカーが送信される.
- 隠れているゾンビを発見することにより, 恐怖・驚きを誘発する.

4.4.3.4 Phase 3: ゾンビ追跡と驚き (Fear & Surprise / Pursuit)

Phase 3 は, 追跡者 (ゾンビ) との遭遇により, 強い恐怖と驚き反応を誘発するフェーズである.

- **目的:** 強い恐怖と特定対象に対する驚き反応を誘発する.
- **メカニズム:** Phase 2 と同一マップで敵 (ゾンビ) 追跡演出を活性化し即時的脅威刺激を提供することで, 高い覚醒と強い恐怖/驚き反応を誘導する. ゾンビがプレイヤーを追跡する (図 4.6 (b)). ゾンビは一定距離内に接近すると停止して威嚇し (図 4.6 (a)), 再び接近を試みる 2 段階近接ロジック (P3_ZOMBIE_NEAR_1, P3_ZOMBIE_NEAR_2) を持つ.
- **終了条件:** プレイヤーが特定のドアを開けて脱出するか, ゾンビと一定回数接触すると EXPERIMENT_END となり全データが保存される.

第5章 実験

本章では、提案した VR 基盤マルチモーダル感情推定フレームワークを検証するために実施した参加者実験の設計と手順を提示する。具体的には、実験の目標と参加者、実験環境、刺激シナリオ、データ収集手順、そしてラベリング基準について順に説明する。

5.1 実験の目的

本実験の目的は Unity で開発した VR ホラーコンテンツを通じてユーザの恐怖および驚き、ならびに付随する緊張や警戒の状態を段階的に誘導し、提案した収集・同期システムを通じて生体信号および行動/イベント反応の変化を捕捉できるか確認することである。さらに収集されたマルチモーダルデータを活用して感情状態分類の可能性を初期評価し、追加実験およびモデル改善点を導出する。本研究の仮説は「VR コンテンツで誘発された恐怖/驚きおよび緊張状態は生体信号の有意な変化として現れ、生体信号と行動、イベント情報を総合した特徴はユーザの感情状態を区分するのに有用である」というものである。

5.2 参加者

本実験には6名が参加した。参加者は平均年齢28歳の健康な成人男性で、VR 使用経験があり心血管系疾患または精神疾患がないことを自己申告した。すべての参加者は事前に実験手順と目的についての説明を聞いて同意書に署名し、実験中いつでも中断を要請する権利があることを告知された。

5.3 実験手順

実験は以下の手順で実施した。

1. **事前説明と同意:** 参加者に実験の目的、手順、および VR ホラーコンテンツを含むことによる潜在的なリスク (VR 酔い、精神的ストレスなど) について説明し、書面による同意を得た。
2. **機器装着:** 参加者に生体センサ (ECG, EDA, EMG) を装着し、信号品質を確認した。その後、HMD とコントローラを装着し、座位にて待機させた。
3. **VR 体験:** 参加者は VR コンテンツを開始し、Phase 0 (ベースライン) から Phase 3 (追跡) までの一連のシナリオを連続して体験した。体験中は生体信号および行動ログを同期して記録した。
4. **事後評価:** VR 体験終了後、機器を取り外し、各フェーズおよび主要イベントにおける主観的な感情状態に関するアンケートに回答した。具体的には、Phase および主要イベントで感じた感情強度 (例: 恐怖、驚き、緊張、集中、没入など) を 7 点 Likert 尺度で評価した (1: 非常に低い, 7: 非常に高い)。

表 5.1 実験フェーズの構成と誘導される感情状態

Phase	名称	環境および課題	誘導感情	予想される生体反応
0	Baseline	暗い部屋, 十字注視 (60 秒)	安定 (Rest)	ベースライン値の測定
1	Task	明るい訓練室, Go/No-Go 課題	集中 (Focus)	認知負荷による軽微な上昇
2	Puzzle	暗い屋敷, アイテム 4 個収集	不安/恐怖 (Fear)	探索に伴う SCL の漸進的上昇
3	Chase	ゾンビ追跡, 脱出	恐怖/驚き (Panic)	HR, SCL, EMG の急激なピーク

表 5.2 収集データの概要

データ種別	センサ/ソース	サンプリング	収集項目
生体信号データ (BITalino)			
EMG	A1 チャンネル	1 kHz	筋電図 RAW 値 (10-bit ADC)
EDA	A2 チャンネル	1 kHz	皮膚電気伝導度 RAW 値
ECG	A3 チャンネル	1 kHz	心電図 RAW 値
イベントログ (Unity → Python)			
Phase 制御	TCP 通信	イベント発生時	Phase 0-3 開始・終了
Go/No-Go 課題	TCP 通信	イベント発生時	試行開始, HIT, MISS, NO_RESPONSE
VR 環境イベント	TCP 通信	イベント発生時	ドア開閉, アイテム獲得, ゾンビ出現・近接

5.4 実験環境

参加者は Meta Quest Pro HMD を装着し, 両手コントローラを使用して座った姿勢で VR コンテンツを体験した. 生体信号測定のために BITalino(PLUX Biosignals) 生体信号収集キットを使用した.

5.5 刺激シナリオ

本実験では, 第 4 章で詳述した 4 段階のフェーズ構成に基づき, 参加者に一連の VR 体験を提示した. 実験は Phase 0(ベースライン) から開始し, Phase 1(集中課題), Phase 2(探索と予期不安), Phase 3(追跡と驚き) の順に連続して進行した. 各フェーズは, 参加者の生理的・心理的状态を段階的に変化させることを意図しており, 特に Phase 2 から Phase 3 にかけては, 視覚・聴覚的演出 (照明の低下, BGM の変化, ゾンビの出現) を強化することで, 不安から恐怖, そしてパニックに近い驚き反応へと感情を誘導した. 各フェーズにおける具体的な実験条件および誘導目標となる感情状態の対応を表 5.1 にまとめる.

5.6 データ収集

参加者が VR コンテンツを開始すると生体信号およびイベント/行動ログ収集が同時に開始される. 表 5.2 に収集データの概要を示す.

図 5.1 に例として参加者 (Subject E2) の連続生体信号データを示す. Phase 2 から Phase 3 にかけて SCL の上昇および EMG の反応増加が観察される.




図 5.1 連続生体信号記録 (Subject E2). 上から EMG エンベロープ, EDA(SCL), ECG フィルタ済み信号. 各 Phase は背景色で区別される (Phase 0: 青, Phase 1: 橙, Phase 2: 赤, Phase 3: 紫).

図 5.2 に各 Phase 別の取得データ, 図 5.3 に前処理後の信号と抽出特徴量を示す.

5.7 ラベリング

収集された生体データには, システムが自動付与する客観的ラベルと, 参加者の事後報告に基づく主観的ラベルを併用する.

客観的ラベルは, 表 5.3 に示す VR アプリケーションから送信される主要イベントマーカーに基づいて付与される. 図 5.4 に示すように, 各イベント発生時点 (t_0) を中心に前後 2.5 秒 (計 5 秒間) のウィンドウを設定し, 該当区間の特徴量を抽出した. この窓幅は, EDA の皮膚電気反応が刺激提示後 1–4 秒で最大振幅に達すること [15, 16], および VR 環境における感情認識研究での標準的な分析窓 [10, 17] に基づき設定した.

主観的ラベルは, 実験直後に参加者が回答した事後アンケートに基づいて付与される. 詳細は表 5.5 に示す通りである.

5.7.1 結果

表 5.6 に全参加者 (6 名, 8 セッション) の Phase 別生体反応統計量を示す. 図 5.5 に示すように, Phase 2 から Phase 3 にかけて SCL および EMG の上昇傾向が確認されるなど, Phase 0 から Phase 3 に向かって生体反応の変化が確認された.




図 5.2 Subject E2 の Phase 別取得データ. 各列は Phase 0–3 を, 各行は EMG,EDA,ECG を示す. 赤点線は Phase 内の平均値.

さらに, 図 5.7 および図 5.8 に参加者別の生体反応パターンを示す. 図 5.7 から個人差が大きいことが確認され, 図 5.8 のヒートマップ (色が濃いほど値が高い) からは, SCL が Phase 2 から 3 にかけて全体的に上昇傾向を示していることが読み取れる. Subject E1, E2 は Phase 3 で顕著な LF/HF 上昇を示し, Subject D は Phase 3 で EMG RMS の著しい増加を示した. 一方, Subject A, F は Phase 全体を通じて比較的安定した反応パターンを示した.



図 5.3 Subject E2 の Phase 別前処理済み信号と特徴量. 第 1 行: EMG エンベロープ, 第 2 行: EDA(SCL), 第 3 行: ECG(R-peak 検出), 第 4 行: 主要特徴量.

表 5.3 主要イベントマーカー

Phase	マーカー	説明
Phase 0	BASELINE_START/END	ベースライン測定 (60 秒)
Phase 1	P1_TRIAL_ONSET	Go/No-Go 試行開始
Phase 2	P2_PIECE_1~4	アイテム獲得
	P2_ZOMBIE_DOOR	ゾンビ扉出現
Phase 3	CHASE_START	追跡開始
	P3_ZOMBIE_NEAR	ゾンビ近接




図 5.4 イベントマーカーと分析ウィンドウの定義. 各イベント発生時点 (t_0) を中心に前後 2.5 秒 (計 5 秒間) のウィンドウを設定.

表 5.4 実験後アンケート回答結果の要約

ID	探索 (Q2-1)	収集 (Q2-3)	扉開放 (Q2-6)	追跡認知 (Q3-1)	追跡対峙 (Q3-2)	解放感 (Q3-3)	備考
A	2	3	5	6	3	5	後半恐怖上昇, 典型的パターン
B	6	5	5	7	4	2	全体的に高い恐怖度, 周囲の騒音言及
C	4	4	6	6	7	6	一貫して高い恐怖および緊張維持
D	2	2	3	3	1	1	「ゾンビ追跡気づかず」, 低い恐怖度
E	5	6	6	6	7	7	非常に高い恐怖反応および解放感
F	3	5	6	1	1	6	「追跡認知できず」, 特異なパターン

表 5.5 事後アンケート詳細結果 (7 点 Likert 尺度, 平均 $\pm$ SD)

質問 ID	評価項目 (イベント内容)	平均	SD
Q2-1	暗い屋敷の探索開始時の恐怖/不安	3.33	1.51
Q2-2	1 つ目のアイテム獲得時の恐怖/不安	2.83	1.17
Q2-3	2 つ目のアイテム獲得および BGM 変化時の緊張	4.17	1.47
Q2-4	3 つ目のアイテム獲得時の驚き	4.33	1.37
Q2-5	4 つ目のアイテム獲得直後の演出変化に対する恐怖	4.17	2.14
Q2-6	ゾンビ部屋のドアを初めて開けた瞬間の恐怖/緊張	5.50	1.38
Q3-1	ゾンビの追跡を認知した瞬間の恐怖/緊張	4.33	2.58
Q3-2	ゾンビが近くで停止した時の恐怖/緊張	4.50	2.52
Q3-3	実験終了時の緊張解放感の程度	4.00	2.00

表 5.6 全参加者の Phase 別生体反応統計量 (6 名,8 セッション,Mean $\pm$ SD)

特徴量	Phase 0	Phase 1	Phase 2	Phase 3
心拍数 (bpm)	73.0 $\pm$ 11.7	74.2 $\pm$ 9.5	76.5 $\pm$ 8.1	72.2 $\pm$ 20.2
HRV RMSSD (ms)	143.3 $\pm$ 284.5	51.4 $\pm$ 32.7	67.0 $\pm$ 53.0	742.4 $\pm$ 1775.9
LF/HF 比	1.7 $\pm$ 1.1	2.4 $\pm$ 1.9	1.9 $\pm$ 1.3	1.6 $\pm$ 2.5
SCL (μ S)	22.2 $\pm$ 6.2	20.9 $\pm$ 6.5	26.6 $\pm$ 3.0	26.7 $\pm$ 1.5
EMG Mean (μ V)	14.9 $\pm$ 7.2	15.9 $\pm$ 8.4	19.8 $\pm$ 7.9	27.7 $\pm$ 17.4
EMG RMS (μ V)	16.9 $\pm$ 6.6	18.2 $\pm$ 6.6	25.4 $\pm$ 8.9	36.0 $\pm$ 30.1

Mean Physiological Response by Phase (N=8, Mean $\pm$ SD)




図 5.5 Phase 別平均生体反応 (6 名,8 セッション,Mean $\pm$ SD)

Phase-wise Physiological Response Comparison (N=8)




図 5.6 Phase 別生体反応の箱ひげ図 (6 名, 8 セッション).

Individual Subject Variation by Phase




図 5.7 参加者別 Phase 変動

Subject × Phase Heatmap




図 5.8 参加者 × Phase ヒートマップ

第 6 章 実験結果

本章では、実施した実験から得られたデータの分析結果を提示する。まず主観的なアンケート評価の結果を述べ、続いて生体信号の客観的な統計分析結果を示す。最後に、これらの特徴量を用いた機械学習によるフェーズ分類の性能評価について記述する。

6.1 主観的感情評価分析

実験直後に実施したアンケート結果を分析し、参加者の主観的な感情変化を定量化した。この分析結果は生体信号解釈の基準点として活用される。

6.1.1 参加者別反応の類型化および特異事例の分析

アンケート調査は、大きく分けて Phase 2 の探索パート (Q2-1 ~ Q2-6) と Phase 3 の追跡パート (Q3-1 ~ Q3-3) で構成された。参加者の回答を総合した結果、ゾンビがいる部屋のドアを開けた瞬間 (Q2-6) およびゾンビが追跡を開始した時点 (Q3-1) において、最も高い恐怖値が記録された。

主観報告に基づき、参加者の反応パターンを以下の 3 つのタイプに分類した。

1. 没入型恐怖反応群 (Immersion-Fear Group: A, B, C, E) このグループは、実験の進行に伴い恐怖値が線形に上昇する傾向を示した。特に参加者 E は、ゾンビ追跡状況 (Q3-1, Q3-2) において最高値である 7 点を記録し、極度の恐怖と緊張を訴えた。これらの参加者は VR 環境が提供する視聴覚刺激を現実的な脅威として受容しており、VR 刺激に対する受容反応は、後述する生体信号の急激な変化とも一致する結果であった。

2. 認知失敗群 (Cognitive Failure Group: D, F) 認知失敗群は、特定の状況を明確に認知できず、感情生起が抑制された事例群である。参加者 D は、ゾンビが追跡している事実を認知できなかったと回答し、その結果 Q3-1 のスコアは 1 点にとどまった。参加者 F も同様の認知失敗を報告し、事後インタビューにおいて「Q3-1, Q3-2 の状況を認知できなかった」と明言した。認知失敗による感情生起の抑制は、VR 内での感情変動が参加者の注意および認知的評価プロセスに大きく依存することを示している。

3. 選択的知覚反応群 (Selective Perception Group: F) 選択的知覚反応群は、持続的な恐怖よりも瞬間的な驚き刺激に敏感に反応したケースである。参加者 F は、追跡状況は認知できなかったものの、ゾンビ部屋のドアを開けた瞬間 (Q2-6) には 6 点という高い緊張度を報告した。高い緊張度の報告は、特定の演出が意図した感情を誘発することに成功したことを意味し、全体的な文脈への没入とは別に、瞬間的なインパクトが生体反応に影響を与えた可能性を示している。

6.2 客観的生体反応分析: フェーズ別統計および指標分析

収集された生体信号 (EDA, ECG, EMG) について、各フェーズごとの統計的变化と特徴的な反応パターンを分析する。

表 6.1 全参加者のフェーズ別 EDA (SCL) 統計値 (Mean ± SD)

フェーズ (Phase)	平均 SCL (μS)	標準偏差 (SD)	最小値 (Min)	最大値 (Max)
Phase 0	22.20	6.22	9.05	28.02
Phase 1	20.90	6.51	7.55	28.09
Phase 2	26.59	2.99	19.42	28.20
Phase 3	26.67	1.47	23.94	27.82

表 6.2 全参加者のフェーズ別 ECG/HRV 主要統計値 (Mean ± SD)

特徴量 (Feature)	Phase 0	Phase 1	Phase 2	Phase 3
平均心拍数 (HR, bpm)	73.02 ± 11.65	74.15 ± 9.54	76.52 ± 8.11	72.16 ± 20.23
RMSSD (ms)	143.34 ± 284.51	51.42 ± 32.71	67.04 ± 53.03	742.37 ± 1775.91
SDNN (ms)	126.01 ± 193.24	54.86 ± 32.56	68.30 ± 35.40	459.45 ± 1051.43
LF/HF 比	1.72 ± 1.10	2.37 ± 1.95	1.87 ± 1.26	1.58 ± 2.50

6.2.1 皮膚電気活動 (EDA) 分析結果

皮膚電気活動は交感神経系の活性度を表す核心的な指標であり、本実験では SCL の平均値を中心に分析した。

データ分析の結果、Phase 0 と Phase 1 の間では有意な SCL の上昇は観察されなかったが、暗い屋敷を探索し始める Phase 2 に進入すると、SCL 平均値が 26.59 μS へと急激に上昇した。SCL 平均値の上昇は、視覚的制限と環境音が参加者の警戒心を高め、交感神経系を持続的に覚醒させたことを意味する。Phase 3 でも 26.67 μS の高い水準が維持され、標準偏差が 1.47 μS と非常に低く現れた点は、すべての参加者が共通して高い覚醒状態に到達したことを示している。特に SCR ピーク数については、Phase 1 で平均 7.88 回であったものが、探索と追跡が含まれるシナリオにおいて持続的に発生し、脅威刺激に対する反応性を証明した。

6.2.2 心拍変動 (HRV) および心電図 (ECG) 分析結果

心電図データを基に算出された心拍数と心拍変動指標は、参加者の自律神経系バランスとストレスレベルを表す。表 6.2 に全参加者のフェーズ別 ECG/HRV 主要統計値を示す。

生理学的指標は個人間で大きな変動を示すため、各参加者の Phase 0 (安静状態) における測定値をベースラインとして使用し、以降のフェーズにおける値をベースラインからの変化率として算出した (表 6.3)。具体的には、以下の式に示すように、各フェーズの測定値をベースライン値と比較し、パーセント変化率に変換した。

$$\Delta X_{\text{norm}}(\%) = \frac{X_{\text{Phase}_n} - X_{\text{Phase}_0}}{X_{\text{Phase}_0}} \times 100$$

正規化された結果から、以下の傾向が確認された。心拍数は Phase 2 で平均+4.8%の上昇を示し、探索過程における持続的な緊張状態を反映した。Phase 3 では平均-1.2%と微減したが、標準偏差が 27.7%と顕著に増大しており、「すくみ反応 (Freezing Response)」による心拍数低下とパニック反応による心拍数急増が参加者間で混在した結果であると解釈される。

時間領域 HRV 指標である RMSSD と SDNN は、Phase 1 においてそれぞれ-64.1%、-56.5%と大幅に減少し

表 6.3 ベースライン正規化後のフェーズ別 ECG/HRV 変化率 (% , Mean $\pm$ SD)

特徴量	Phase 1	Phase 2	Phase 3
心拍数変化率	+1.5 $\pm$ 13.1	+4.8 $\pm$ 11.1	-1.2 $\pm$ 27.7
RMSSD 変化率	-64.1 $\pm$ 22.8	-53.2 $\pm$ 37.0	+417.9 $\pm$ 1239.0
SDNN 変化率	-56.5 $\pm$ 25.8	-45.8 $\pm$ 28.1	+264.6 $\pm$ 834.4
LF/HF 変化率	+37.3 $\pm$ 113.1	+8.8 $\pm$ 73.1	-8.1 $\pm$ 145.0

表 6.4 全参加者のフェーズ別 EMG 主要統計値 (Mean $\pm$ SD)

特徴量 (Feature)	Phase 0	Phase 1	Phase 2	Phase 3
平均電圧 (Mean, μ V)	14.90 $\pm$ 7.17	15.95 $\pm$ 8.36	19.83 $\pm$ 7.94	27.69 $\pm$ 17.36
RMS 電圧 (RMS, μ V)	16.87 $\pm$ 6.63	18.23 $\pm$ 6.61	25.40 $\pm$ 8.93	36.01 $\pm$ 30.05
最大電圧 (Max, μ V)	81.86 $\pm$ 60.27	104.03 $\pm$ 66.30	228.27 $\pm$ 190.88	223.11 $\pm$ 302.27

た. この減少は認知的負荷が副交感神経活動を抑制し, ストレス反応を誘導したことを定量的に示している. Phase 3 における異常な上昇 (+417.9%, +264.6%) は, 一部参加者の激しい不整脈様反応や身体動作によるアーティファクトが反映された結果と推定され, 今後の分析において精密なノイズ除去の必要性を示唆している.

周波数領域の LF/HF 比は Phase 1 で+37.3%と最も顕著な上昇を示し, Go/No-Go 課題における高度な集中と交感神経系の活性化を意味する. Phase 2 以降は漸減し, Phase 3 では-8.1%とベースラインをやや下回った.

6.2.3 筋電図 (EMG) 分析結果

右腕の筋肉に装着された EMG センサは, 参加者の身体的緊張度と驚き反応に伴う筋肉収縮を測定した.

EMG 分析の結果, フェーズが進行するにつれて筋肉の緊張度が明確に上昇する様相が観察された. 特に Phase 3 における RMS 電圧は 36.01 μ V であり, Baseline (16.87 μ V) と比較して 2 倍以上に増加し, 最大電圧は平均 223.11 μ V になった. EMG の増加は, ゾンビの追跡という直接的な脅威の前で, 被験者が逃避あるいは防御のために身体筋肉を強く収縮させたことを裏付ける証拠である. また, 標準偏差が 30.05 μ V と非常に大きく現れた点は, 被験者の傾向によって身体的硬直反応の程度が極端に分かれたことを示唆している.

6.3 個人差分析および特異反応者の識別：主観・客観連携の深層事例

全体統計分析を超え, 主観的報告と生体反応の間の相関関係を明確に把握するため, 主要な参加者 3 名に対する深層事例分析を実施した.

6.3.1 特異な反応を示す参加者 (Subject E2)

参加者 E2 は, アンケートにおいて追跡時の恐怖度 7 点と解放感 7 点を同時に記録した「没入度が高い」参加者である. 同参加者の生体データは, このような主観的報告を強く裏付けている.

Phase 3 において EMG RMS 値が 57.01 μ V へと急増したが, これは全参加者平均 (36.0 μ V) の 1.5 倍以上に達する数値である. 同時に心拍数は 100.4 bpm と高く測定され, 強力な交感神経系の活性化を示した. RMSSD は 154.4 ms を記録し, この値は単純な安静ではなく, 強いストレス反応を示唆している. 主観的にも最も高い恐怖度 (7 点) を報告しており, 客観的生体信号と主観的経験が最もよく一致するパターンを示した.

表 6.5 機械学習に使用した特徴量

信号種別	特徴量
ECG	心拍数,HRV (RMSSD, SDNN, pNN50),LF/HF 比,R-peak 数,RR 間隔統計
EMG	平均値, 標準偏差, 最大値,RMS, 積分 EMG
EDA	平均 SCL,SCL 標準偏差, 平均 SCR, 最大 SCR,SCR ピーク数

6.3.2 認知失敗および低反応者 (Subject D)

参加者 D は、主観的に追跡を認知できなかったと報告しており、追跡を認知できなかったことは生体指標の停滞につながった。

- **SCL 減少:** Phase 2 (28.20 μ S) から Phase 3 (23.94 μ S) へと覚醒数値が下落した。
- **安定的 HR:** 心拍数もまた 77.77 bpm から 78.65 bpm へとほとんど変化がなかった。
- **EMG 低下:** 筋電図 (EMG) もまた 12.65 μ V と Baseline よりも低く測定され、身体的緊張が完全に解消されたことを示している。

以上の結果は「実験課題が無事に終了した」と判断し、急激な心理的弛緩状態に進入したことを示唆する。このようなベースライン以下への生体指標の下落は、感情推定フレームワークが単に恐怖の有無だけでなく、ユーザが現在の状況を「安全」あるいは「終了」と認知しているか否かを判別する有用な指標となり得ることを示している。

6.3.3 無意識的緊張維持者 (Subject F)

参加者 F は事後アンケートにおいて追跡を認知できなかったと回答したが、同参加者の身体は異なる反応を示していた。

- **高い覚醒水準:** Phase 3 の SCL 値は 25.32 μ S であり、全参加者の Phase 3 平均である 26.67 μ S に近接した数値である。心拍数は 90.39 bpm で実験全体の中で最高値を記録し、EMG RMS もまた 35.17 μ V で平均以上の高い身体的緊張度を示した。
- **SCR ピークの存在:** 特に Phase 2 において 16 回の SCR ピークが発生したが、SCR ピークの頻発は、参加者 F がアイテムを収集する過程ですでに相当な心理的圧迫を感じていたことを意味する。

「追跡を認知できなかった」という回答は、実際の追跡状況における視覚的認知失敗を意味するだけであり、参加者 F が置かれていた環境全体に対する緊張感は解消されていなかったことを示唆する。

6.4 機械学習による自動 Phase 分類

生体信号特徴量のみを用いて実験 Phase を自動分類する機械学習モデルを構築し、その性能を評価した。

6.4.1 手法

機械学習を用いた Phase 分類モデルの構築手順、使用した特徴量、および検証方法について述べる。

特徴量として、表 6.5 に示す 20 個の生理学的特徴量を使用した。

一般化性能を評価するため、Leave-One-Session-Out 交差検証を用いた。本実験では 6 名の参加者から 8

表 6.6 Phase 分類モデルの性能比較 (LOSO 交差検証)

モデル	Accuracy	F1-Score	Precision	Recall
Random Forest	0.677	0.666	0.704	0.677
Gradient Boosting	0.645	0.637	0.655	0.645
SVM (RBF)	0.452	0.465	0.507	0.452
k-NN	0.452	0.421	0.449	0.452
Logistic Regression	0.484	0.495	0.516	0.484




図 6.1 Phase 分類モデルの性能比較

セッションのデータを収集した (2 名が 2 回参加)。各 fold(計 8 回) では 1 セッションをテストセット, 残り 7 セッションをトレーニングセットとして使用した。なお, 同一参加者の複数セッション (Subject B: 2 セッション, Subject E: 2 セッション) がトレーニングとテストに分かれる場合があるため, 本評価は厳密な個人間一般化性能ではなく, 新規セッションへの汎化性能を示している。

分類アルゴリズムとして, 以下の 5 種類の機械学習アルゴリズムを比較評価した: Random Forest, Gradient Boosting, SVM (RBF kernel), k-NN, Logistic Regression。

6.4.2 分類結果

構築した機械学習モデルの分類性能を, 精度指標および混同行列を用いて評価した結果を示す。

まずモデルごとの性能比較について述べる。表 6.6 に各モデルの LOSO 交差検証による性能を示す。

Random Forest が最高性能 (Accuracy: 67.7%, F1: 66.6%) を達成した。図 6.1 に各モデルの性能比較を示すが, Random Forest と Gradient Boosting が他モデルを上回る性能を示していることがわかる。

次に混同行列による分析結果を示す。図 6.2 に Random Forest モデルの混同行列を示す。図より, Random Forest では Phase 0 (BASELINE) が 88%, Phase 3 (CHASE) が 71%の再現率を示しており, 安定状態と恐怖状態の識別に優れていることが確認された。

Phase 別の分類性能は以下の通りである：

- **Phase 0 (BASELINE):** Recall 88%, 安定した生体信号パターンにより高い識別率




図 6.2 各モデルの正規化混同行列

- **Phase 1 (TASK):** Recall 38%, Phase 0 との混同が多く, 認知課題による生理的变化が限定的
- **Phase 2 (PUZZLE):** Recall 75%, 探索活動に伴う EMG・EDA 上昇が特徴的
- **Phase 3 (CHASE):** Recall 71%, 恐怖反応による顕著な生理的变化を捕捉

さらに特徴量重要度の分析を行った. 図 6.3 に Random Forest モデルにおける特徴量重要度を示す. 図 6.3 から明らかなように, ECG_num_r_peaks(R-peak 数), EMG_integrated_emg(積分 EMG), EMG_std_uV(EMG 標準偏差) が上位を占めており, 識別に大きく寄与している.

上位 5 特徴量は以下の通りである:

1. **ECG_num_r_peaks** (16.1%): 心拍活動の総量
2. **EMG_integrated_emg** (9.3%): 累積筋活動量
3. **EMG_std_uV** (8.0%): 筋活動の変動性
4. **EDA_mean_SCL_uS** (7.2%): 平均皮膚電気伝導度
5. **EDA_mean_SCR_uS** (5.8%): 平均皮膚電気反応

最後に参加者別の分類精度について述べる. 図 6.4 に参加者別の分類精度を示す. 図 6.4 に示す通り, Subject B2, E2 は 100%の精度を達成した一方, Subject A は 33%と低精度であり, 個人による精度のばらつきが大きいことが確認された.

参加者間で大きな精度差が観察された (33%–100%). この結果は, 個人差を考慮したキャリブレーションの必要性を示唆している.




図 6.3 Random Forest モデルの特徴量重要度




図 6.4 参加者別 Phase 分類精度

第7章 考察

本章では、実験を通じて得られた生体信号データに基づき、VR 環境における恐怖刺激がユーザの心理および生理状態に与える影響について考察する。具体的には、各実験フェーズにおける皮膚電気活動、心電図、筋電図の変化傾向と、参加者に見られた特異的な反応(すくみ現象など)を分析する。続いて、機械学習モデルを用いたフェーズ分類の性能評価を行い、特徴量の重要度について論じる。最後に、本研究の技術的境界とリアルタイム感情認識システムの高度化に向けた今後の課題について述べる。

7.1 実験結果の解釈および生体信号の反応

本研究で構築した感情推定フレームワークは、VR 環境においてユーザが感じる感情変化をリアルタイムに捕捉することを目的としている。実験設計に従って進行された 4 段階のフェーズ (Phase 0-3) を通じて、ユーザの心理状態が安定した状態から恐怖状態へと段階的に変化することが確認され、心理状態の段階的变化は、収集された生体データによって裏付けられた。特に皮膚電気活動、心電図、筋電図を統合的に分析することで、個別の信号のみでは把握が困難なユーザの内面状態をより多面的に理解することが可能となった。

データを具体的に見ると、SCL は探索が開始される Phase 2 において前段階よりも大きく上昇して約 26.59 μ S を記録し、ゾンビが出現する Phase 3 まで高い水準を維持した。SCL の持続的上昇は、VR の視覚的制限と音響効果がユーザの緊張感を効果的に高めたことを示している。特に Phase 3 においてすべての参加者の SCL 値が一様に高く現れた点は、この段階で共通して強い覚醒状態を経験したことを示唆する。

一方で心拍数は少し異なる様相を示した。Phase 2 までは漸進的に上昇したが、最も恐ろしい刺激が与えられる Phase 3 において、むしろ平均値が 72.16 bpm へと低下しつつ参加者ごとの偏差が大きくなった。心拍数の低下と偏差の増大は、単に平均心拍数のみで感情を判断することが困難であることを示しており、「すくみ (Freezing) 反応」のような個人ごとの対応方式の差異が反映された結果であると考えられる。

7.2 参加者別特異反応とすくみ (Freezing) 現象

本実験で注目すべき部分は、参加者ごとに現れた反応の差異である。特に参加者 E2 の事例は注目に値する。E2 はアンケートにおいてゾンビ追跡状況に対して満点である 7 点の恐怖を感じたと回答した。しかし実際の生体データでは、Phase 3 の心拍数が 28.96 bpm まで低下する非正常な徐脈現象が現れ、心拍変動指標は非常に高く測定された。

非正常な徐脈現象と高い RMSSD 値は、心理学で言われる「恐怖誘発性徐脈」、すなわちすくみ反応の典型的な姿である。脅威を感じた際に身体の動きを止めて周囲に集中する防御機制が作動したものであり、この時、副交感神経が強く活性化されながら心拍数が急激に低下することになる。E2 の筋電図値が平均より 3 倍も高かった点を考慮すれば、外見上は動いていなかったが、体内では著しく緊張し筋肉を収縮させていたことが分かる。

参加者 D と F の事例も興味深い。D はゾンビが追いかけてきていることに気づかず恐怖点数として 1 点のみを与え、生体データでも緊張が解ける様子が現れた。一方で F は本人も追跡を認知できなかったと回答し

たが、実際の身体反応 (SCL, HR, EMG) は全体平均よりも高いか同等の水準を維持した。高い身体反応の維持は、意識的には脅威を知らなかったとしても、VR 環境の全般的な雰囲気のために無意識的な緊張状態が継続していたことを示している。

7.3 機械学習基盤フェーズ分類の意義および特徴量分析

機械学習モデルを通じて実験フェーズを自動的に分類した結果、Random Forest モデルが 67.7 %の精度を記録した。67.7 %の精度は、4つの状態を分類する問題において無作為確率 (25%) よりも約 2.7 倍高い性能である。このような結果は、センサから抽出された生理的特徴量が VR 体験中の心理状態変化を有意に反映していることを立証する。特に安定状態 (Phase 0) と追跡状態 (Phase 3) の識別率が高く現れたが、高い識別率は、恐怖状況で発生する生体反応の明確な変化をモデルが効果的に捕捉できることを意味する。

特徴量重要度を分析してみると、筋電図 (積分 EMG, 標準偏差) と皮膚コンダクタンス (平均 SCL, 平均 SCR) がフェーズ識別に有効な役割を果たした。これらの指標は恐怖と緊張状態で発生する交感神経系の活性化をよく示しており、今後のリアルタイム感情認識システムにおいても有用であることが期待される。

ただし、心電図の R-peak 数 (ECG_num_r_peaks) が最も重要な指標として選ばれた点は注意が必要である。R-peak 数の重要度が高い結果は、実験設計上、フェーズごとの持続時間が異なっていた点 (Phase 2 は長く、Phase 3 は短い) がモデル学習に反映された持続時間バイアスである可能性が高い。したがって、真の意味での感情認識のためには、特徴量を単位時間当たりの比率として正規化する過程が必要である。

7.4 リアルタイム感情認識システム高度化のための展望

本研究で構築した分類モデルは、リアルタイム感情認識フレームワークへと進むための予備検証段階である。実際のサービスで活用可能な水準のシステムを構築するためには、次のような課題を解決する必要がある。

第一に、学習ラベルの再定義が必要である。現在は実験段階 (文脈情報) を分類対象としたが、実用的なシステムのためには、ユーザが直接報告した主観的感情スコア (恐怖度、緊張度など) を分類目標としなければならない。アンケート結果を活用して「高恐怖状態」と「低恐怖状態」などに感情ラベルを細分化して再学習させれば、モデルの実用性がさらに高まると考えられる。

第二に、時間分解能の改善である。本研究では数十秒から分単位のフェーズ分類を実施したが、リアルタイムコンテンツに応用するには秒単位の精密な推定が必要である。このためにスライディングウィンドウ方式を導入し、連続的に感情状態を推定する手法が必要である。

第三に、個人適応型メカニズムの導入である。参加者ごとに精度偏差 (33% ~ 100%) が大きく現れたことは、個人ごとの生理的特性の差異を示している。実用システムでは、体験前の短いキャリブレーションセッションを通じて個人の基底反応を学習し、学習した基底反応に基づきモデルを補正する機能が重要である。

7.5 技術的限界および改善方向

システム実装において最も大きな技術的課題は、動きによるノイズの制御であった。VR 環境の特性上、ユーザが頭を素早く回したり身体を縮こまらせたりする過程で、生体信号に深刻な歪みが発生する。具体的には以下のようなノイズが発生し、信号解析を困難にした。

まず、基線変動である。これは呼吸や身体の高い動きにより、ECG や EDA 信号の基準軸が大きく揺らぐ現象を指す。次に、筋電図混入および震えが挙げられる。恐怖により身体が震えたり筋肉に力が入ったりする際に発生する電気信号が、ECG 信号と混ざり R-peak 検出を妨げる問題である。さらに、電極接触不良も深刻な問題であった。激しい動きにより電極と皮膚間のインピーダンスが変化したり、瞬間的に電極が浮いたりすることで、生体信号より数十倍の電圧ノイズが発生する現象である。

これらのノイズ問題を解決するために、BITalino の 3 軸加速度センサ (ACC, 測定範囲 $\pm 3g$, 帯域幅 0–50 Hz) を活用して動きデータを確保する必要がある。BITalino 加速度センサは身体の X, Y, Z 軸の加速度変化をリアルタイムで測定し、「どの方向にどれほど強く動いたか」に関する参照データを提供する。

今後、システムの高度化段階においては、この 3 軸加速度データを「ノイズ参照信号」として利用し、適応フィルタを適用する計画である。適応フィルタアルゴリズム (例: LMS, RLS など) は、加速度データと生体信号間の相関関係を分析し、生体信号から動きによって発生した成分のみをリアルタイムで推定して除去する。これにより、激しい追跡状況 (Phase 3) においても歪みのない純粋な心拍数と皮膚伝導度データを確保し、感情推定の精度を大幅に向上させることができると期待される。

第8章 結論

本研究では、VR 体験中のユーザの没入感を阻害することなく、内面的な感情状態を客観的に評価するために、生体信号 (EDA, ECG, EMG) と VR 内イベントおよび行動ログをリアルタイムに同期して記録できるマルチモーダル感情推定フレームワークを構築した。提案システムは、Unity エンジンと外部生体センサデバイス間の TCP/IP 通信を通じて同期を実現し、この同期により特定のコンテンツイベントとユーザの生理的反応の間の因果関係を究明できる土台を設けた。

実験を通じて収集されたデータを分析した結果、恐怖と緊張が高まるシナリオにおいて皮膚電気活動の急激な上昇と筋電図の活性化が一貫して観察された。特に機械学習基盤のフェーズ分類モデルは約 67.7% の精度を達成し、ランダム確率を大きく上回る性能を示し、安定状態 (Recall 88%) と追跡/驚き状態 (Recall 71%) において高い識別力を実証した。また、一部の参加者に見られた恐怖誘発性徐脈と身体硬直を伴う「すくみ」反応を客観的指標として捉えることで、主観的アンケートだけでは把握が難しい深層的な情動的没入度を評価できる可能性を確認した。

技術的限界および今後の課題として、本研究は初期段階の探索的研究であり、いくつかの課題を残している。まず参加者数とセッション数の不足により、モデルの一般化性能を十分に確保することに限界があり、体験中に発生する激しい動きによる信号ノイズが心拍指標の安定性を阻害する要因となった。

したがって、今後の研究では加速度計データを参照信号として活用した能動的ノイズ除去アルゴリズムを強化し、データ規模を大幅に拡大して個人間の偏差を克服できる一般化モデルを構築する必要がある。また、現在のフェーズ単位の分類から進んで、ユーザの主観的評価に基づいた「高恐怖/低恐怖」のような詳細な感情ラベルを再定義し、スライディングウィンドウ手法を導入して秒単位のリアルタイム推定が可能なシステムへと発展させるべきである。

本フレームワークが高度化され実際の現場に適用される場合、次のような社会的・技術的波及効果が期待される。

第一に、医療および心理治療分野の革新である。本技術は外傷後ストレス障害や不安障害治療のための VR 暴露療法において、患者のストレスレベルをリアルタイムにモニタリングし、患者の状態に合わせて刺激の強度を動的に調整するオーダーメイド治療システムの核心エンジンとして活用できる。これは治療の安全性を高め、効果を最大化することに寄与するであろう。

第二に、教育および訓練環境の高度化である。医療スタッフの手術シミュレーションや産業現場の危険予知訓練において、学習者が感じる認知負荷と緊張度を客観的に評価し、個人別フィードバックを提供することで、実質的な実務能力を涵養するのに役立つ。また、特殊教育分野において感情表現が苦手な学生の内面状態を把握し、よりきめ細かい教育環境を造成することに寄与するであろう。

第三に、次世代ユーザ体験およびインタラクションデザインの変化である。コンテンツ制作者はユーザの感情反応データを基に、意図した演出が効果的に伝達されたかを客観的に検証し、この検証を通じてより精巧な「アフェクティブ・ループ」を実現できる。ユーザの気分に応じて背景音楽や照明、難易度がリアルタイムに変化する「知能型反応型コンテンツ」は、メタバースやソーシャル VR 環境において没入感を飛躍的に高めるであろう。

謝 辞

本研究を進めるにあたり、終始懇切丁寧なご指導とご鞭撻を賜りました関西学院大学工学部知能・機械工学課程 井村誠孝教授に、謹んで深甚なる謝意を表します。また、本研究の遂行にあたり、有益なご討論ならびにご指導を賜りました関西学院大学工学部知能・機械工学課程 河野恭之教授、宮原啓造教授に、心より感謝申し上げます。さらに、本研究の遂行に際し、実験にご協力賜りました参加者の皆様には、貴重なお時間を割いてご参加いただき、多大なるご協力を賜りましたことをここに記し、深く感謝申し上げます。

参考文献

- [1] Javier Marín-Morales, Carmen Llinares, Jaime Guixeres, and Mariano Alcañiz. Emotion recognition in immersive Virtual Reality: From statistics to affective computing. *Sensors*, Vol. 20, No. 18, p. 5163, 2020.
- [2] C. E. Orozco-Mora, R. Q. Fuentes-Aguilar, and G. Hernández-Melgarejo. Dynamic difficulty adaptation based on stress detection for a Virtual Reality video game: A pilot study. *Electronics*, Vol. 13, No. 12, p. 2324, 2024.
- [3] L. Shu, J. Xie, M. Yang, Z. Li, Z. Li, D. Liao, X. Xu, and X. Yang. A review of emotion recognition using physiological signals. *Sensors*, Vol. 18, No. 7, p. 2074, 2018.
- [4] D. Liao, L. Shu, G. Liang, Y. Li, et al. Design and evaluation of affective Virtual Reality system based on multimodal physiological signals and Self-Assessment Manikin. *IEEE Journal of Electromagnetics, RF and Microwaves in Medicine and Biology*, Vol. 4, No. 3, pp. 216–223, 2020.
- [5] M. N. Dar, M. U. Akram, S. G. Khawaja, and A. N. Pujari. CNN and LSTM-based emotion charting using physiological signals. *Sensors*, Vol. 20, No. 16, p. 4551, 2020.
- [6] L. B. Hinkle, K. K. Roudposhti, and V. Metsis. Physiological measurement for emotion recognition in Virtual Reality. In *2019 2nd International Conference on Data Intelligence and Security*, pp. 136–143, 2019.
- [7] D. Pajić, S. Sadiković, M. Oljača, et al. Risky behavior in virtual reality: The roles of personality, environment, and physiology. *PLoS ONE*, Vol. 20, No. 1, p. e0316896, 2025.
- [8] J. H. T. Lin. Fear in Virtual Reality (VR): Fear elements, coping reactions, immediate and next-day fright responses toward a survival horror zombie virtual reality game. *Computers in Human Behavior*, Vol. 72, pp. 350–361, 2017.
- [9] Y. Çimtay, E. Ekmekcioglu, and S. Çağlar Özhan. Cross-subject multimodal emotion recognition based on hybrid fusion. *IEEE Access*, Vol. 8, pp. 168865–168875, 2020.
- [10] J. Marín-Morales, J. L. Higuera-Trujillo, A. Greco, J. Guixeres, C. Llinares, E. P. Scilingo, M. Alcañiz, and G. Valenza. Affective computing in Virtual Reality: Emotion recognition from brain and heartbeat dynamics using wearable sensors. *Scientific Reports*, Vol. 8, No. 1, p. 13657, 2018.
- [11] E. E. Arslan, M. F. Akşahin, M. Yilmaz, and H. E. Ilgın. Towards emotionally intelligent virtual environments: Classifying emotions through a biosignal-based approach. *Applied Sciences*, Vol. 14, No. 19, p. 8769, 2024.
- [12] N. Dozio, et al. A design methodology for affective Virtual Reality. *International Journal of Human-Computer Studies*, Vol. 162, p. 102791, 2022.
- [13] Radiah Rivu, Paula Prodan, Ville Mäkelä, Pascal Knierim, and Florian Alt. How are your participants feeling today? accounting for and assessing emotions in Virtual Reality. In *Proceedings of Mensch und Computer 2023*, pp. 37–48, 2023.
- [14] Task Force of the European Society of Cardiology and the North American Society of Pacing and Electrophysiology. Heart rate variability: standards of measurement, physiological interpretation and clinical use.

- Circulation*, Vol. 93, No. 5, pp. 1043–1065, 1996.
- [15] Mathias Benedek and Christian Kaernbach. A continuous measure of phasic electrodermal activity. *Journal of Neuroscience Methods*, Vol. 190, No. 1, pp. 80–91, 2010.
- [16] Jason J. Braithwaite, Derrick G. Watson, Robert Jones, and Mickey Rowe. A guide for analysing electrodermal activity (EDA) & skin conductance responses (SCRs) for psychological experiments. Technical report, University of Birmingham, 2013.
- [17] Sylvia D. Kreibig. Autonomic nervous system activity in emotion: A review. *Biological Psychology*, Vol. 84, No. 3, pp. 394–421, 2010.

研究業績

趙 聖化, 井村 誠孝: VR コンテンツ体験時における生体・行動情報の統合に基づくリアルタイム感情推定フレームワーク, 第 30 回日本バーチャルリアリティ学会大会論文集, 2B2-08, 2025.