

理工学研究科

2026年3月

卒業論文

**VRコンテンツ体験時における生体情報に
基づくリアルタイム感情推定フレームワーク**

27020856 趙 聖化

(人間システム工学科)

VR コンテンツ体験時における生体情報に基づくリアルタイム感情推定フレームワーク

趙 聖化

内容梗概

2010 年代以降の HMD の普及に伴い、ゲームや教育をはじめ様々な分野で没入型の VR(Virtual Reality) 体験が普及している。ユーザに提供される感情的な体験を適切に評価することが求められるが、従来の評価はアンケートなど主観的手法に依存しており、リアルタイム性の欠如やバイアスの影響など多くの課題がある。本研究の目的は、VR 体験におけるユーザの感情状態を客観的に評価する方法を探索することである。

本研究では、生体センサと視線追跡を組み合わせた機械学習システムにより、VR 体験中の感情をリアルタイム推定するフレームワークを提案する。具体的には、皮膚電気活動 (EDA)、心電図 (ECG) から算出される心拍変動 (HRV)、筋電図 (EMG) などの生体信号と、コントローラ操作ログを同時に収集し、多角的に解析する。マルチモーダルな情報を統合して恐怖・驚き・集中などの感情状態を識別することで、VR コンテンツの感情的効果をリアルタイムに評価可能なシステムを構築する。

(ここはまだ仮説 これから書きます) 提案手法の有効性を検証するため、Unity を用いた VR ホラーコンテンツで被験者実験を行った。その結果、恐怖刺激に対して EDA が急激に上昇し、HRV 指標の低下や EMG 信号の変化が確認された。また、被験者間で生体反応の大きさに個人差が見られ、恐怖時に動作が一時停止するフリーズ反応（すくみ反応）も一部で観測された。得られた知見は、生体・行動情報に基づくリアルタイム感情推定の有効性を示しており、VR 体験の客観的評価手法として本フレームワークが有用である可能性を示唆する。

キーワード

アフェクティブコンピューティング, 生理心理学, マルチモーダルデータ融合

目次

第 1 章	序論	1
第 2 章	関連研究	3
2.1	生体信号に基づく感情推定	3
2.2	行動データに基づく注意および感情推定	3
2.3	マルチモーダル感情推定	4
2.4	感情実験設計およびラベリング手法	4
第 3 章	提案手法	7
3.1	ハードウェアインターフェースおよびセンサ構成	7
3.2	生体信号の前処理および数値変換モデル	7
3.2.1	心電図 (ECG) および筋電図 (EMG) の変換と前処理	7
3.2.2	皮膚電気活動 (EDA) の変換と前処理	8
3.3	特徴抽出	8
3.3.1	ECG 特徴	9
3.3.1.1	時間領域 HRV 指標	9
3.3.1.2	周波数領域 HRV 指標	9
3.3.2	EMG 特徴	9
3.3.3	EDA 特徴	9
3.4	ユーザ入力およびイベントログの活用	10
3.4.1	ユーザ入力 (User Input)	10
3.4.2	システムイベント (System Events)	10
3.4.3	統合解析 (Integration)	10
第 4 章	実装	11
4.1	開発環境およびシステム構成	11
4.2	ハードウェア構成	11
4.2.1	VR HMD: Meta Quest Pro	11
4.2.2	BITalino センサシステム	11
4.2.3	センサチャンネル構成および付着位置	12
4.3	ソフトウェア構成	12
4.4	システムアーキテクチャおよびデータ同期	12
4.4.1	Unity-Python 間 TCP 同期設計	12
4.4.2	イベントログフォーマットと時間同期方式	12
4.5	Unity 側のシステム構成	13
4.5.1	BitalinoController.cs の設計	13
4.5.2	コンテンツ設計の基本コンセプト	13
4.5.3	4 段階実験フェーズ構成	14

4.5.3.1	Phase 0: ベースライン (Baseline)	14
4.5.3.2	Phase 1: 集中課題 (Focus / Go/No-Go Task)	14
4.5.3.3	Phase 2: 屋敷探索と予期不安 (Fear / Exploration)	14
4.5.3.4	Phase 3: ゾンビ追跡と驚き (Fear & Surprise / Pursuit)	15
第 5 章	実験	17
5.1	実験設計および方法	17
5.1.1	実験目標	17
5.1.2	参加者	17
5.1.3	実験手順	17
5.1.4	実験環境	18
5.1.5	刺激シナリオ	18
5.1.6	データ収集	18
5.1.7	ラベリング	20
5.1.7.1	客観的ラベル	20
5.1.7.2	主観的ラベル	22
5.1.8	全体統計	22
5.1.9	個人差分析	24
第 6 章	実験結果	27
6.1	主観的感情評価分析	27
6.1.1	被験者別反応の類型化および特異事例の分析	27
6.2	客観的生体反応分析: フェーズ別統計および指標分析	27
6.2.1	皮膚電気活動 (EDA) 分析結果	27
6.2.2	心拍変動 (HRV) および心電図 (ECG) 分析結果	28
6.2.3	筋電図 (EMG) 分析結果	28
6.3	個人差分析および特異反応者の識別: 主観・客観連携の深層事例	29
6.3.1	極端的反応者 (Subject E2)	29
6.3.2	認知失敗および低反応者 (Subject D)	29
6.3.3	無意識的緊張維持者 (Subject F)	29
6.4	機械学習による自動 Phase 分類	30
6.4.1	手法	30
6.4.1.1	特徴量	30
6.4.1.2	交差検証	30
6.4.1.3	分類アルゴリズム	30
6.4.2	分類結果	30
6.4.2.1	モデル比較	30
6.4.2.2	混同行列分析	32
6.4.2.3	特徴量重要度	32
6.4.2.4	参加者別分類精度	33
第 7 章	考察	35
7.1	実験結果の解釈および生体信号の反応	35

7.2	参加者別特異反応とすくみ (Freezing) 現象	35
7.3	機械学習基盤フェーズ分類の意義および特徴量分析	36
7.4	リアルタイム感情認識システム高度化のための展望	36
7.5	技術的限界および改善方向	36
第 8 章	結論	39
	謝辞	41
	参考文献	43
	付録	45
A	本文と直接関係ない知識	45

表目次

3.1 抽出された生理学的特徴量の一覧	8
5.1 実験フェーズの構成と誘導される感情状態	18
5.2 収集データの概要	18
5.3 主要イベントマーカー	20
5.4 実験後アンケート回答結果の要約	22
5.5 事後アンケート詳細結果 (7 点 Likert 尺度, 平均 $\pm$ SD)	22
5.6 全参加者の Phase 別生体反応統計量 (6 名, 8 セッション, Mean $\pm$ SD)	22
6.1 全参加者のフェーズ別 EDA (SCL) 統計値 (Mean $\pm$ SD)	28
6.2 全参加者のフェーズ別 ECG/HRV 主要統計値 (Mean $\pm$ SD)	28
6.3 全参加者のフェーズ別 EMG 主要統計値 (Mean $\pm$ SD)	29
6.4 機械学習に使用した特徴量	30
6.5 Phase 分類モデルの性能比較 (LOSO 交差検証)	31

図目次

4.1 各生体センサの付着位置	12
4.2 提案システムのデータフロー図および TCP 同期メカニズム	13
4.3 Phase 0: ベースライン測定 (安定)	14
4.4 Phase 1: 集中課題 (Go/No-Go Task)	15
4.5 Phase 2: 屋敷探索と予期不安	15
4.6 Phase 3: ゾンビ追跡と驚き	16
5.1 連続生体信号記録 (Subject E2). 上から EMG エンベロープ, EDA (SCL), ECG フィルタ済み 信号. 各 Phase は背景色で区別される (Phase 0: 青, Phase 1: 橙, Phase 2: 赤, Phase 3: 紫). . . .	19
5.2 Subject E2 の Phase 別生データ. 各列は Phase 0-3 を, 各行は EMG, EDA, ECG を示す. 赤点 線は Phase 内の平均値.	20
5.3 Subject E2 の Phase 別前処理済み信号と特徴量. 第 1 行: EMG エンベロープ, 第 2 行: EDA (SCL), 第 3 行: ECG (R-peak 検出), 第 4 行: 主要特徴量.	21
5.4 イベントマーカーと分析ウィンドウの定義. 各イベント発生時点 (t_0) を中心に前後 2.5 秒 (計 5 秒間) のウィンドウを設定.	21
5.5 Phase 別平均生体反応 (6 名, 8 セッション, Mean $\pm$ SD). Phase 2 から Phase 3 にかけて SCL および EMG の上昇が確認される.	23
5.6 Phase 別生体反応の箱ひげ図 (6 名, 8 セッション).	24
5.7 参加者別 Phase 変動. Subject A-F (6 名, 8 セッション) の各 Phase 別生体反応. 個人差が大き いことが確認された.	25
5.8 参加者 $\times$ Phase ヒートマップ. 色が濃いほど値が高い. SCL は Phase 2-3 で全体的に上昇傾向を 示す.	26
6.1 Phase 分類モデルの性能比較. Random Forest と Gradient Boosting が他モデルを上回る性能を示 した.	31
6.2 各モデルの正規化混同行列. Random Forest では Phase 0 (BASELINE) が 88%, Phase 3 (CHASE) が 71%の再現率を示した.	32
6.3 Random Forest モデルの特徴量重要度. ECG_num_r_peaks (R-peak 数), EMG_integrated_emg (積分 EMG), EMG_std_uV (EMG 標準偏差) が上位を占めた.	33
6.4 参加者別 Phase 分類精度. Subject B2, E2 は 100%の精度を達成した一方, Subject A は 33%と 低精度であった.	34

第1章 序論

VR(Virtual Reality) 技術が急速に発展し、エンターテインメント、教育、医療など様々な分野で没入型の VR 体験が提供されるようになってきている。VR コンテンツではユーザに恐怖や興奮、感動といった強い感情的体験を与えることが可能であり、感情を引き出す効果を高めるための工夫が重ねられている。一方で、VR 体験がユーザに与える感情的影響や体験の質を客観的に評価することは容易ではない。特に、VR コンテンツ制作者が意図する感情体験がユーザに確実に伝わっているかを検証することは重要な課題であるが、適切な評価手法は確立されていないのが現状である。

VR 体験の効果やユーザの感情反応を評価する際には、アンケートやインタビューなど体験後の主観評価に頼ることが一般的である。しかし、主観的な評価には回答者のバイアスや記憶の曖昧さが影響する上、体験中の瞬間瞬間の感情変化を捉えることはできない。また、評価のために体験を中断してその場で質問を行うことは没入感の阻害につながるため、リアルタイムでユーザの感情状態を検出することは困難である。

この問題に対し、工学的アプローチとして、ユーザの生体信号や行動データを用いて感情状態を客観的に推定する方法が注目されている。人間の感情は自律神経系の反応として生理指標に現れることが知られており、例えば皮膚電気活動 (Electrodermal Activity; EDA) は交感神経の活動度を反映する指標で、恐怖や驚きにより覚醒度が高まるとき顕著な上昇を示す。心電図 (Electrocardiogram; ECG) から得られる心拍変動 (Heart Rate Variability; HRV) は副交感神経と交感神経のバランスを示す指標であり、一般にストレス下では HRV が低下する傾向が知られている [1, 2]。さらに、筋電図 (Electromyography; EMG) は筋肉の活動を測定する手法で、驚いた際の瞬発的な筋反応や持続的な筋緊張度の変化を捉えることができる。

また、コントローラの操作頻度や動作の変化も感情反応の指標となり得る。たとえば、突発的な驚き刺激に対して咄嗟に操作が乱れる、あるいは強い恐怖に直面して一時的に操作が止まる「すくみ (Freezing)」といった現象が考えられる。以上のように、生体情報と行動情報の双方をマルチモーダルに取得・分析することで、単一の指標では捉えきれないユーザの内面的な感情変化をより正確に推定できると期待される。

本研究では、マルチモーダルな生体・行動情報の分析というアプローチに基づき、VR 体験中のユーザの感情状態をリアルタイムに推定するフレームワークを提案する。本研究の目的は、生体情報と行動データの統合解析によって VR コンテンツの感情的効果を客観的に評価する手法を確立することである。具体的には、EDA、HRV、EMG といった生体センサ情報と、コントローラの操作ログを同時に取得し、収集したデータを Unity 上の VR コンテンツのイベントと同期させることで、恐怖・驚き・集中といった感情状態を識別するためのデータセットを構築する。構築したデータを用いて機械学習モデルを訓練し、マルチモーダルな特徴量に基づくリアルタイム感情推定を実現することを目指す。

本論文の構成は以下の通りである。第2章では関連研究について述べる。第3章では提案手法であるマルチモーダル感情推定フレームワークについて説明する。第4章ではシステムの実装詳細について述べ、第5章では被験者実験の設計と手順を説明する。第6章では実験結果と考察を示し、最後に第7章で本論文を総括する。

第2章 関連研究

本章では、本研究に関連する先行研究および基礎知識について述べる。まず生体信号を用いた感情推定手法について概説し、次に行動データに基づく注意および感情推定手法を紹介する。続いて、複数のモダリティを統合するマルチモーダル感情推定の最新動向を考察し、最後に感情実験の設計およびラベリング手法について説明する。

2.1 生体信号に基づく感情推定

生体信号に基づく感情推定は、顔表情や音声のような外見の手がかりに依存する手法と比較して、主観的な操作や偽装が困難であり、自律神経系および中枢神経系の反応を直接捉えることができるという点で客観性と再現性に優れている [1]。

顔表情や音声などの物理的信号は社会的な文脈に応じて意図的に抑制・加工が可能であるが、心電図、皮膚電気活動、筋電図などは自律神経系によって不随意に制御されるため、ユーザの本質的な内的状態を高い信頼性で反映する [3]。

特に VR 環境では HMD の装着により顔領域の可視性が制限され、伝統的な表情認識手法の適用が困難であるが、心電図、皮膚電気活動、筋電図、脳波などの信号は、ユーザの没入感を阻害することなく同時に収集することが容易である [1, 4]。

収集された生体データは、VR コンテンツの設計において、どの場面で肯定的あるいは否定的な情動反応が生じたかを特定する客観的フィードバックや、ユーザの状態に応じて刺激強度や提示様式を調整する適応型 VR の基盤情報として活用できる [1, 2]。ただし、生体信号は感情のみに特異的な信号ではなく、運動・発話・姿勢変化や VR 酔いなどの要因によっても変動するため、実験設計段階での統制と、アーティファクト除去、ベースライン補正などの信号処理が不可欠である [1]。

深層学習技術の発展は、生体信号の複雑な非線形パターンの学習に寄与している。Dar らは、14 チャンネル EEG の不規則な構造的特性を反映するために、EEG 信号を 81×128 サイズの 2 次元画像にマッピングして空間的特徴を抽出する 2D-CNN アーキテクチャを提案している [5]。ECG と GSR 信号に対しては、1D-CNN と LSTM を結合して信号の局所的な時間的特徴と長期的な依存関係を同時に学習することで、感情状態を精密に識別できることを実証している [5]。

自律神経系指標の中で、心拍変動と皮膚電気活動は情動的覚醒を反映する核心的な指標として広く活用されている。一般に恐怖のような高覚醒刺激時には交感神経系が活性化し、心拍数 (HR) が上昇し、HRV 指標 (RMSSD など) が低下する傾向を示す。Hinkle らは VR 環境において EDA 信号のみを用いて高覚醒/低覚醒状態を区別し、SVM および k-NN 分類器を通じて最大 89% の認識精度を達成している [6]。

2.2 行動データに基づく注意および感情推定

ユーザの行動ログは生理的反応と密接に関連しており、注意の集中度や情動状態を間接的に推定する重要な手がかりとなる。VR 環境では、視線追跡、頭部および身体の動き、コントローラ操作ログなどが主要なデー

タソースとして活用される。その中でも視線追跡データは HMD 内蔵のアイトラッカーを通じて取得可能であり、注視対象や探索パターンを通じてユーザの関心度や脅威回避行動を分析することに寄与する。

また、コントローラ操作頻度や反応遅延時間などの能動的インタラクションログは、没入度や恐怖反応を推論するツールとして使用される。恐怖状況において、ユーザが逃避のために操作を高頻度で行ったり、逆に極度の恐怖によって身体や操作が一時的に停止する「すくみ (Freeze)」現象が観察されることがある [7]。このようなすくみ反応は脅威に対する人間の本能的な防御機制であり、VR 内でも頭部や手の移動速度が瞬間的に低下する時系列パターンを通じて捕捉可能である [8]。行動パターンをイベントのタイムラインと同期させて分析することで、ユーザの注意の方向と刺激に対する立体的な情動反応を把握することができる。

2.3 マルチモーダル感情推定

マルチモーダル感情推定は、異なる 2 つ以上のデータソースを結合して対象の状態を推定する方法であり、感情認識分野でも複数の信号を融合することで性能向上を図る研究が増加している。単一の生体信号や単一の行動指標だけでは得られる情報に限界があるが、複数の指標を相互補完的に結合することで、より正確で堅牢な感情分類が可能になる。

生体信号を用いた感情推定研究は活発に行われており、複数の生体信号を組み合わせることで単一センサーよりも推定精度が向上することが報告されている [1, 9]。特に VR 環境下では、脳波 (EEG) と心拍変動 (HRV) を用いて感情価と覚醒度を推定する研究 [10] や、ユーザの心拍数反応に応じてゲームの難易度をリアルタイムかつ動的に調整する試み [2] などがあり、これは生体情報とコンテンツ間の密接な相互作用である「アフェクティブ・ループ」の実現可能性を裏付けている。

このようなマルチモーダルアプローチの優位性は、大規模データセットを用いた実験を通じても証明されている。Dar ら (2020) は EEG, ECG, GSR 信号を統合し、AMIGOS データセットで 99.0%、DREAMER データセットで 90.8% の感情分類精度を達成した [5]。この精度は単一モダリティを使用した場合よりも飛躍的に高い数値であり、異なる生体信号が感情の多様な側面を相互補完的に説明していることを示唆している [5]。

Arslan ら (2024) は、ECG と GSR 信号に統計的特徴選択手法を結合して 97.78% の高い精度を記録した [11]。彼らは興奮、幸福、不安、平穏、悲しみの 5 つの感情状態を分類したが、一部の感情間の境界が曖昧であり、新規ユーザへの一般化に限界があることも報告している [11]。多くの研究が特定の条件下での感情分類に留まっており、多様な VR 体験や個人ごとの生理的偏差を包括できる汎用的なフレームワークは未だ確立されていないのが実情である。

本研究はこのような限界を克服するため、生体信号 (EDA, ECG, EMG) と行動データを統合し、リアルタイムのイベント同期とベースライン補正を適用した汎用的な感情推定モデルの構築を目指す。

2.4 感情実験設計およびラベリング手法

感情状態を科学的に研究するためには、信頼性の高い感情誘発シナリオの設計と正確な正解ラベル (Ground Truth) の確保が必須である。VR は従来のメディアよりも強力な没入感を提供し、恐怖や驚きなどの反応を誘発するのに最適化されている [4]。恐怖研究では、ジャンプスケア要素や照明、音などを活用した環境デザインが主に用いられ [12]、Radiah らは、バーチャル環境のレイアウト、色彩、音、装飾、天候という 5 つの次元のデザイン空間を提案し、各次元のデザインをリアルタイムで制御してユーザの感情を誘発および評価できる “EmotionEditor” ツールボックスを開発した [13]。このようなツールは実験設計の体系性を高め、

研究者が意図した感情状態をより精密に誘導できるようにする。

ラベリング手法は大きく分けて、客観的イベントベースのラベリングと主観的自己報告ラベリングに区別される。イベントベースの方式は特定の刺激発生時点を基準にラベルを割り当てるためデータ同期が容易である反面、自己報告方式は SAM(Self-Assessment Manikin) などの尺度を通じて実際のユーザが感じた感情の強度を数値化する [1, 4]。本研究では主要イベント直後に事後アンケートを実施して獲得した感情強度ラベルを生体データと対照分析することで、データセットの信頼性を確保する。

第3章 提案手法

本研究では,VR 環境における没入感を阻害することなく,ユーザの内面的な感情状態を客観的に把握するためのリアルタイム感情推定フレームワークを提案する. 本フレームワークは,高精度生体信号センサと VR HMD (Head Mounted Display) の行動ログを統合し,感情状態を多角的に分析する [1].

3.1 ハードウェアインターフェースおよびセンサ構成

ユーザの身体反応測定のために以下のようなセンサを使用する.

- EMG : 右腕に REF 電極を電氣的に中立的な骨部位 (bone region) に付着し, IN+および IN- 電極を筋繊維方向に整列されるように筋腹 (Muscle belly) の上に 20 mm 間隔で付着して,筋肉の電氣的活動および緊張度を測定する.
- EDA : 右手のひらに電極を付着し,皮膚伝導度の変化を測定する [6].
- ECG : REF 電極を腸骨稜 (iliac crest) に付着し, IN+および IN- 電極を胸部に付着して,心電図信号を測定する.

センサ付着後には電極接触安定化のために必要な手順を遂行した.

3.2 生体信号の前処理および数値変換モデル

BITalino センサから収集される生データを物理的意味を持つ単位に変換するため,以下のような変換を適用する. 生体信号取得システムの動作電圧を V_{CC} ,ADC 解像度を n ビットとする.

3.2.1 心電図 (ECG) および筋電図 (EMG) の変換と前処理

$$ECG(V) = \left(\frac{ADC}{2^n - 1} - 0.5 \right) \times \frac{V_{CC}}{G_{ECG}}$$
$$EMG(mV) = \left(\frac{ADC}{2^n} - 0.5 \right) \times V_{CC} \times \frac{1000}{G_{EMG}}$$

変換された信号は以下のように前処理される.

- ECG: 0.5–40 Hz 帯域通過フィルタを適用した後,R-peak 検出を実行する.
- EMG: 20–450 Hz 帯域通過フィルタリング後,整流および包絡線抽出を通じて筋肉緊張度を算出する.

表 3.1 抽出された生理学的特徴量の一覧

信号	特徴量	単位	生理学的意義
ECG	心拍数 (HR)	bpm	全般的な覚醒水準
	RMSSD	ms	副交感神経活動
	SDNN	ms	全体的 HRV (交感+副交感)
	pNN50	%	副交感神経活動比率
	LF パワー	ms ²	交感+副交感神経活動
	HF パワー	ms ²	副交感神経活動
	LF/HF 比	-	自律神経バランス (ストレス指標)
EMG	平均電圧	μV	筋緊張の基礎水準
	最大電圧	μV	筋活動のピーク強度
	RMS 電圧	μV	筋活動エネルギー
EDA	平均 SCL	μS	基礎的覚醒水準
	SCR パルス数	回	刺激に対する反応頻度

3.2.2 皮膚電気活動 (EDA) の変換と前処理

皮膚導電率は, 以下の関数を用いてマイクロジーメンズ (μS) 単位に変換される。

$$EDA(\mu S) = \frac{ADC}{2^n} \times \frac{V_{CC}}{0.132}$$

本公式の分母の 0.132 は EDA センサーの回路設計に基づく伝達関数の定数である。EDA 信号は 0.5 Hz 低域通過フィルタ (LPF) を適用した後, 緩やかに変化する SCL (Tonic) 成分と特定の刺激による急激な変化を表す SCR (Phasic) 成分に分解して処理する。

SCL (Skin Conductance Level, Tonic): 皮膚コンダクタンスの基底レベルを意味する長期的なトニック反応 (Tonic level) である。SCL は背景覚醒レベルを反映し, 心理的ストレスや環境的要因によって数十秒から数分にわたって緩やかに変化する特性を持つ。一般的に一定区間の皮膚コンダクタンス信号の平均または中央値として算出され, 自律神経系緊張度の基底状態を表す指標として活用される。

SCR (Skin Conductance Response, Phasic): 特定のイベント (Event) や刺激に対する反応として現れる短期的かつ急激な位相性反応 (Phasic response) である。刺激直後約 1–5 秒以内にコンダクタンスが急激に増加し, 該当刺激に対する神経生理学的覚醒度を直接的に反映する。SCR 振幅 (SCR_{amp}) は反応の最大値 (SC_{peak}) と反応開始時点のレベル (SC_{onset}) の差として定義され, 以下のように算出する。

$$SCR_{amp} = SC_{peak} - SC_{onset}$$

3.3 特徴抽出

前処理された各信号から感情推定に有効な時系列特徴量を抽出する。本研究では, 感情状態を反映する生理学的指標として以下の特徴量を算出する [3]。

3.3.1 ECG 特徴

心電図から心拍数および心拍変動（HRV）指標を抽出し、自律神経系反応を分析する。

3.3.1.1 時間領域 HRV 指標

- 平均心拍数 (HR): 1 分間あたりの心拍数 (bpm)
- RMSSD: 連続する RR 間隔の差分の二乗平均平方根であり、副交感神経の活動指標として広く用いられる。

$$\text{RMSSD} = \sqrt{\frac{1}{N-1} \sum_{i=1}^{N-1} (RR_{i+1} - RR_i)^2} \quad (3.1)$$

- SDNN: NN 間隔の標準偏差であり、交感・副交感神経の両方を含む全体的な HRV 指標である。

$$\text{SDNN} = \sqrt{\frac{1}{N} \sum_{i=1}^N (RR_i - \overline{RR})^2} \quad (3.2)$$

- pNN50: 連続する RR 間隔の差が 50ms 以上である割合 (%) であり、副交感神経活動を反映する。

3.3.1.2 周波数領域 HRV 指標

RR 間隔時系列を FFT により周波数領域に変換し、パワースペクトル密度を算出する [?].

- LF パワー (0.04-0.15 Hz): 交感神経と副交感神経の両方の活動を反映
- HF パワー (0.15-0.40 Hz): 副交感神経活動（呼吸性洞性不整脈）を反映
- LF/HF 比: 自律神経系バランス指標。値が高いほどストレス状態を示す

$$\text{LF/HF} = \frac{\int_{0.04}^{0.15} \text{PSD}(f) df}{\int_{0.15}^{0.40} \text{PSD}(f) df} \quad (3.3)$$

3.3.2 EMG 特徴

筋肉活動の強度を定量化するため、以下の特徴量を算出する。

- 平均電圧, 最大電圧 (μV)
- RMS 電圧: 筋活動の全体的なエネルギー量

$$\text{RMS} = \sqrt{\frac{1}{N} \sum_{i=1}^N x_i^2} \quad (3.4)$$

3.3.3 EDA 特徴

- 平均 SCL (μS): 基礎的な覚醒水準を示す皮膚電気伝導度の平均値
- SCR パルス数: 刺激に対する一過性反応の回数 [6]

3.4 ユーザ入力およびイベントログの活用

本提案手法では、生体信号のみならず、VR 環境内でのユーザの行動 (入力) とシステム側で発生するイベントを統合的に解析することで、感情推定の精度と解釈性を向上させる。

3.4.1 ユーザ入力 (User Input)

VR コントローラの操作ログと HMD のトラッキングデータを取得し、ユーザの能動的な行動を分析する。

- **トリガー・ボタン入力:** Phase 1 での射撃課題 (Right Trigger) や、Phase 2 での懐中電灯操作 (Left Trigger) およびアイテム収集 (Ray/Trigger) など、意図的なインタラクションを記録する。
- **トラッキングデータ (Position/Rotation):** HMD およびコントローラの 6 自由度 (6DoF) データを記録する。これにより、驚き刺激に対する瞬発的な回避動作や、強い恐怖に直面した際の身体硬直 (Freezing) 反応などの行動的特徴を抽出することが可能となる。特に Phase 3 では、プレイヤーの視線ベクトルとゾンビの位置関係から「直視 (Gaze)」イベントを判定するために活用される。

3.4.2 システムイベント (System Events)

VR コンテンツの進行状況や特定の刺激発生タイミングをイベントマーカーとして記録し、生体信号の文脈 (Context) として活用する。

- **フェーズ遷移:** PHASE1_TASK_START, PHASE3_START など、実験フェーズの切り替わりを記録し、ベースラインとの比較やフェーズごとの状態推定に使用する。
- **タスク・イベント:** Phase 1 の試行開始 (P1_TRIAL_ONSET_GO), Phase 2 のアイテム獲得 (P2_PIECE_n), Phase 3 のゾンビ接近 (P3_ZOMBIE_NEAR_n) など、感情変化のトリガーとなる瞬間を特定する。
- **環境変化:** ドアの開閉 (DOOR_OPEN) や BGM の切り替えタイミングなどを記録し、環境要因によるストレス変化を分析する。

3.4.3 統合解析 (Integration)

収集された生体信号 (EDA, ECG, EMG) とイベントログは、共通のタイムスタンプおよびサンプルインデックス (sample_index) を用いて厳密に同期される。これにより、「ゾンビが接近した瞬間」や「アイテムを発見した瞬間」など、特定の感情生起イベント直後の生理反応 (SCR のピーク、心拍数の急上昇など) をセグメンテーションし、イベントと生体反応の因果関係を明確にした分析が可能となる。

第 4 章 実装

本章では、提案されたシステムを実際に実装した過程を具体的に記述する。使用したハードウェアとソフトウェア環境を紹介し、各モジュールの具体的な実装方法を説明する。

4.1 開発環境およびシステム構成

本研究における VR コンテンツの実装および実行環境は Unity を基盤としており、HMD には Meta Quest Pro を使用した。言語およびシステム構成は以下の通りである。

- Unity 側: C# (VR コンテンツ/イベント発生, TCP クライアント)
- Python 側: TCP サーバ + BITalino データ収集/ロギングモジュール

Unity (C#) と Python 間の通信は TCP ソケット通信で構成し、Unity プロジェクト内の主要通信スクリプトは `BitalinoController.cs`、Python 側は `bitalino_unity_server.py` として役割を分離した。

4.2 ハードウェア構成

4.2.1 VR HMD: Meta Quest Pro


本実験では、Meta Quest Pro をヘッドマウントディスプレイとして使用した。被験者は両手のコントローラを用いて VR 空間内を移動し、特定のインタラクション（ドアの開閉、アイテム取得など）を行うことで、システムへの入力と行動データの収集を行った。

4.2.2 BITalino センサシステム

被験者の生理的反応を測定するために BITalino (r)evolution ボードを使用した。BITalino デバイスは EMG、ECG、EDA などのアナログ生体信号を測定し、これを 10-bit ADC を通じてデジタル化して出力する。データのサンプリング周波数は 1000 Hz に設定した。

収集された各センサのデジタル値は専用センサデータシートに提示された変換式を通じて物理的単位に換算される。本研究では、前述の提案手法（第 3 章）で示した数式を用いて各信号の変換処理を行う。具体的なシステムパラメータは以下の通りである。

- 動作電圧 (V_{CC}): 3.3 V
- ADC 解像度 (n): 10-bit (0 ~ 1023)
- センサ別ゲイン定数 (Gain): BITalino (r)evolution センサの製造元 (PLUX Biosignals) 公式データシートに定義された固有値を適用した。
 - 心電図 (ECG): $G_{ECG} = 1100$
 - 筋電図 (EMG): $G_{EMG} = 1009$



(a) EMG センサ付着位置 (Channel A1) (b) EDA センサ付着位置 (Channel A2) (c) ECG センサ付着位置 (Channel A3)

図 4.1 各生体センサの付着位置

4.2.3 センサチャンネル構成および付着位置

各センサの付着位置および構成は, 第 3 章 (3.2 節) で提案した手法に準拠する. 具体的なセンサの装着状況を図 4.1 に示す.

4.3 ソフトウェア構成

4.4 システムアーキテクチャおよびデータ同期

本システムは, Unity 2022.3 LTS と Python 分析サーバー間の非同期 TCP/IP ソケット通信を基盤として構築した. 各モジュールの役割とデータフローを整理した図を 4.2 に示す.

4.4.1 Unity–Python 間 TCP 同期設計

本システムの核心は, Unity で発生するイベントタイミングを Python サーバに伝達し, Python が同時に読み取っている BITalino サンプルストリームと結合 (同期) する構造にある. Unity 側では BitalinoController.cs で TcpClient を用いてローカルの Python サーバに接続し, Phase 開始/終了および主要イベント発生時に文字列コマンドを送信する. 送信方式は `writer.WriteLine(cmd)` 形式で改行ベースのメッセージ境界を使用して実装した. 送信コマンドの例は以下の通りである: START, STOP, PHASE0_BASELINE_START/END, PHASE1_TASK_START, P1_TRIAL_ONSET_GO, PHASE2_SCENE_START, P2_PIECE_1~4, PHASE3_START, P3_ZOMBIE_NEAR_1/2, P3_ZOMBIE_LOOK_1, DOOR_OPEN, EXPERIMENT_END など. BitalinoController.cs は実験全体で共通して使用される通信モジュールであるため, シングルトンおよび DontDestroyOnLoad 形式で維持されるように設計し, シーン転換時にも接続状態を保存する.

Python 側は TCP サーバとして動作し, Unity から受信したコマンドをイベントログとして記録すると同時に, BITalino 装置から生体信号サンプルを持続的に読み取り保存する. 特に START 受信時に BITalino 接続および測定を開始し, Unity コマンドをイベント CSV として記録する.

4.4.2 イベントログフォーマットと時間同期方式

イベントログは以下のような CSV フォーマットで記録する.




図 4.2 提案システムのデータフロー図および TCP 同期メカニズム

`unix_time, sample_index, label`

ここで `sample_index` は BITalino 側のサンプルインデックス (または内部カウンタ) で、生理データと Unity イベントを同一時間軸にマッピングする核心キーとして使用する。Unity イベントは「いつ発生したか」をコマンドで伝達し、Python は該当コマンドを受信した時点の `sample_index` を共に記録することで、以後の分析段階で生体信号 (EDA/ECG/EMG) とイベント (ジャンプスケア/ゾンビ接近/ドア開放など) の整列が可能になる。

4.5 Unity 側のシステム構成

Unity プロジェクトでは実験の各 Phase (第 0 相 ~ 第 3 相) に対応するマネージャスクリプト (例: `Phase0Manager`, `Phase1Manager`, `Phase23Manager` など) を作成し、イベント発生時の処理を制御した。

4.5.1 BitalinoController.cs の設計

Unity 環境では `BitalinoController.cs` が通信の中枢を担う。本スクリプトはシングルトンパターンで実装され、シーン転換が発生しても破棄されない特性を持つ。

- **TCP 接続確立:** 実験開始時、Python サーバへの接続を試みる。
- **イベントマーカ送信:** VR 空間で発生する全ての意味的イベント (Phase 転換, アイテム獲得, 敵接近など) を文字列コマンドで構成し、`writer.WriteLine(cmd)` を通じて即時送信する。ネットワーク遅延を最小化するため、非同期スレッドで処理される。

4.5.2 コンテンツ設計の基本コンセプト

本研究で制作した VR コンテンツは、特定の感情状態 (集中, 恐怖, 驚き) を意図的かつ自然に誘発するように設計されたホラーアドベンチャーゲームである。コンテンツは Unity で開発され、暗い屋敷を探索しながらアイテムを収集する「探索型ホラー」形式を採用した。この形式はプレイヤーの自発的行動 (探索) と、システム側の予期せぬ介入 (ジャンプスケア) を結合することで、多様な感情スペクトルをカバーするのに適している。




図 4.3 Phase 0: ベースライン測定 (安定)

4.5.3 4 段階実験フェーズ構成

本研究で制作した VR コンテンツは「ランダム迷路型 VR ホラーゲーム」で構成され、感情状態を段階的に誘導するために Phase 0-3 の順次構造で設計した。また、各フェーズおよびイベントの状況に応じて異なる BGM および効果音を使用した。Phase 2 の探索パートでは不気味で静かな環境音を再生し緊張感を高める。アイテム獲得時には通知音を鳴らす。Phase 3 でゾンビが登場し追跡が始まると、テンポの速い緊迫した追跡用 BGM に切り替えることで、聴覚的刺激による恐怖と焦燥感を増幅させる。実験は生理信号の変化を正確に測定するため、以下の 4 つのフェーズに分割して進行する。

4.5.3.1 Phase 0: ベースライン (Baseline)

- **目的:** 参加者の安静時生理指標の基準値を確保する。
- **環境:** 刺激のない静的な環境で安定した状態で 60 秒間維持を行い基準 (baseline) 生理値を確保する (図 4.3)。

この期間のデータは、個人差の大きい EDA・HRV の変化量を正規化するための基準 (Baseline) として使用される。

4.5.3.2 Phase 1: 集中課題 (Focus / Go/No-Go Task)


- **目的:** 恐怖・驚きの影響がない状態で「純粹集中」状態の生理データを取得する。
- **環境:** 明るいラボ (実験室) 風のトレーニングルーム。
- **メカニズム:** 恐怖要素を排除した反応抑制課題 (Go/No-Go) を遂行させる。正面に現れる緑の球体 (Go) には射撃 (トリガー) 反応, 赤の球体 (No-Go) には反応しない抑制課題 (図 4.4)。約 30 回の試行がランダム間隔で繰り返される。
- **ラベリング:** P1_TRIAL_ONSET_GO などのマーカーで課題遂行中の認知負荷と集中状態を記録する。

4.5.3.3 Phase 2: 屋敷探索と予期不安 (Fear / Exploration)

- **目的:** 視野制限と音響演出で持続的恐怖 (不安) を誘発する。
- **環境:** 暗い屋敷内部 (図 4.5 (a))。
- **制約:** 光源は左手トリガーを押している間のみ点灯する懐中電灯に制限される。




(a) Go 課題 (緑のボール・射撃)



(b) No-Go 課題 (赤のボール・待機)

図 4.4 Phase 1: 集中課題 (Go/No-Go Task)



(a) 屋敷内部の暗い環境




(b) アイテム探索 (ピーカー収集)

図 4.5 Phase 2: 屋敷探索と予期不安

- **課題:** 屋敷内に隠された 4 つのピーカー (ピース) を収集する (図 4.5 (b)). 収集個数に応じて環境が段階的に変化する. 不確実性と緊張を高め, 環境音, 効果音, 照明などの演出を通じて恐怖・警戒状態を誘導する.
 - 1-2 個目: 微細な環境音の変化.
 - 3 個目: 遠くから聞こえる不吉な悲鳴/物体落下音 (ジャンプスケア前兆).
 - 4 個目: 収集完了と同時に Phase 3 強制移動マーカースが送信される.

4.5.3.4 Phase 3: ゾンビ追跡と驚き (Fear & Surprise / Pursuit)

- **目的:** 強い恐怖と特定対象に対する驚き反応を誘発する.
- **メカニズム:** Phase 2 と同一マップで敵 (ゾンビ) 追跡演出を活性化し即時的脅威刺激を提供することで, 高い覚醒と強い恐怖/驚き反応を誘導する. 知能型ゾンビ AI がプレイヤーを追跡する (図 4.6 (b)). ゾンビは一定距離内に接近すると停止して威嚇し (図 4.6 (a)), 再び接近を試みる 2 段階近接ロジック (P3_ZOMBIE_NEAR_1, P3_ZOMBIE_NEAR_2) を持つ.
- **終了条件:** プレイヤーが特定のドアを開けて脱出するか, ゾンビと一定回数接触すると EXPERIMENT_END となり全データが保存される.



(a) 潜んでいるゾンビの発見



(b) ゾンビによる追跡 (恐怖・驚き)

図 4.6 Phase 3: ゾンビ追跡と驚き

第5章 実験

本章では、提案した VR 基盤マルチモーダル感情推定フレームワークを検証するために遂行した予備実験の設計と手順を提示する。具体的に実験環境と装備構成、構成された刺激シナリオ、データ収集および同期方式、そしてラベリング基準を順に説明する。

5.1 実験設計および方法

5.1.1 実験目標

本実験は Unity で開発した VR ホラーコンテンツを通じてユーザの恐怖および驚き、そしてそれに伴う緊張や警戒の状態を段階的に誘導し、提案した収集・同期システムを通じて生体信号および行動/イベント反応の変化を捕捉できるか確認することに目的がある。さらに収集されたマルチモーダルデータを活用して感情状態分類の可能性を初期評価し、追加実験およびモデル改善点を導出する。本研究の仮説は“VR コンテンツで誘発された恐怖/驚きおよび緊張状態は生体信号 (EDA, ECG, EMG など) の有意な変化として現れ、生体信号と行動/イベント情報を総合した特徴はユーザの感情状態を区分するのに有用である”というものである。

5.1.2 参加者

予備実験には6名の被験者が参加した。参加者は平均年齢28歳の健康な成人男性で、VR 使用経験があり心血管系または精神科的疾患がないと自己報告された。すべての参加者は事前に実験手順と目的についての説明を聞いて同意書を作成し、実験中いつでも中断を要請する権利があることを告知された。

5.1.3 実験手順

実験は以下の手順で実施した。

1. 事前説明と同意: 参加者に実験の目的、手順、および VR ホラーコンテンツを含むことによる潜在的なリスク (VR 酔い、精神的ストレスなど) について説明し、書面による同意を得た。
2. 機器装着: 参加者に生体センサ (ECG, EDA, EMG) を装着し、信号品質を確認した。その後、HMD とコントローラを装着し、座位にて待機させた。
3. VR 体験: 参加者は VR コンテンツを開始し、Phase 0(ベースライン) から Phase 3(追跡) までの一連のシナリオを連続して体験した。体験中は生体信号および行動ログを同期して記録した。
4. 事後評価: VR 体験終了後、機器を取り外し、各フェーズおよび主要イベントにおける主観的な感情状態に関するアンケートに回答した。具体的には、Phase および主要イベントで感じた感情強度 (例: 恐怖、驚き、緊張、集中、没入など) を7点 Likert 尺度で評価した (1: 非常に低い, 7: 非常に高い)。

表 5.1 実験フェーズの構成と誘導される感情状態

Phase	名称	環境および課題	誘導感情	予想される生体反応
0	Baseline	暗い部屋, 十字注視 (60 秒)	安定 (Rest)	ベースライン値の測定
1	Task	明るい訓練室, Go/No-Go 課題	集中 (Focus)	認知負荷による軽微な上昇
2	Puzzle	暗い屋敷, ピーカー (Piece)4 個収集	不安/恐怖 (Fear)	探索に伴う SCL の漸進的上昇
3	Chase	ゾンビ追跡, 脱出	恐怖/驚き (Panic)	HR, SCL, EMG の急激なピーク

5.1.4 実験環境

参加者は Meta Quest Pro HMD を装着し, 両手コントローラを使用して座った姿勢で VR コンテンツを体験した. 生体信号測定のために BITalino(PLUX Biosignals) 生体信号収集キットを使用した.

5.1.5 刺激シナリオ

本実験では, 第 4 章で詳述した 4 段階のフェーズ構成に基づき, 参加者に一連の VR 体験を提示した. 実験は Phase 0(ベースライン) から開始し, Phase 1(集中課題), Phase 2(探索と予期不安), Phase 3(追跡と驚き) の順に連続して進行した. 各フェーズは, 参加者の生理的・心理的状态を段階的に変化させることを意図しており, 特に Phase 2 から Phase 3 にかけては, 視覚・聴覚的演出 (照明の低下, BGM の変化, ゾンビの出現) を強化することで, 不安から恐怖, そしてパニックに近い驚き反応へと感情を誘導した. 各フェーズにおける具体的な実験条件および誘導目標となる感情状態の対応を表 5.1 にまとめる.

5.1.6 データ収集

参加者が VR コンテンツを開始すると生体信号およびイベント/行動ログ収集が同時に開始される. 表 5.2 に収集データの概要を示す.

表 5.2 収集データの概要

データ種別	センサ/ソース	サンプリング	収集項目
生体信号データ (BITalino)			
EMG	A1 チャンネル	1 kHz	筋電図 RAW 値 (10-bit ADC)
EDA	A2 チャンネル	1 kHz	皮膚電気伝導度 RAW 値
ECG	A3 チャンネル	1 kHz	心電図 RAW 値
イベントログ (Unity → Python)			
Phase 制御	TCP 通信	イベント発生時	Phase 0–3 開始・終了
Go/No-Go 課題	TCP 通信	イベント発生時	試行開始, HIT, MISS, NO_RESPONSE
VR 環境イベント	TCP 通信	イベント発生時	ドア開閉, ピーカー獲得, ゾンビ出現・近接

図 5.1 に代表参加者 (Subject E2) の連続生体信号データを示す. Phase 2 から Phase 3 にかけて SCL の上昇および EMG の反応増加が観察される.

図 5.2 に各 Phase 別の生データ, 図 5.3 に前処理後の信号と抽出特徴量を示す.




図 5.1 連続生体信号記録 (Subject E2). 上から EMG エンベロープ, EDA (SCL), ECG フィルタ済み信号. 各 Phase は背景色で区別される (Phase 0: 青, Phase 1: 橙, Phase 2: 赤, Phase 3: 紫).




図 5.2 Subject E2 の Phase 別生データ. 各列は Phase 0–3 を, 各行は EMG, EDA, ECG を示す. 赤点線は Phase 内の平均値.

5.1.7 ラベリング

収集された生体データには, システムが自動付与する「客観的ラベル」と, 参加者の事後報告に基づく「主観的ラベル」を併用する.

5.1.7.1 客観的ラベル

表 5.3 に VR アプリケーションから送信される主要イベントマーカを示す. 図 5.4 に示すように, 各イベント発生時点 (t_0) を中心に前後 2.5 秒 (計 5 秒間) のウィンドウを設定し, 該当区間の特徴量を抽出した. この窓幅は, EDA の皮膚電気反応が刺激提示後 1–4 秒で最大振幅に達すること [14, 15], および VR 環境における感情認識研究での標準的な分析窓 [10, 16] に基づき設定した.

表 5.3 主要イベントマーカ

Phase	マーカ	説明
Phase 0	BASELINE_START/END	ベースライン測定 (60 秒)
Phase 1	P1_TRIAL_ONSET	Go/No-Go 試行開始
Phase 2	P2_PIECE_1~4	ビーカー獲得
	P2_ZOMBIE_DOOR	ゾンビ扉出現
Phase 3	CHASE_START	追跡開始
	P3_ZOMBIE_NEAR	ゾンビ近接



図 5.3 Subject E2 の Phase 別前処理済み信号と特徴量．第 1 行: EMG エンベロープ, 第 2 行: EDA (SCL), 第 3 行: ECG (R-peak 検出), 第 4 行: 主要特徴量．




図 5.4 イベントマーカーと分析ウィンドウの定義．各イベント発生時点 (t_0) を中心に前後 2.5 秒 (計 5 秒間) のウィンドウを設定．

5.1.7.2 主観的ラベル

実験直後、参加者は表??に示す事後アンケートに回答した（7点 Likert 尺度）。

表 5.4 実験後アンケート回答結果の要約

ID	探索 (Q2-1)	収集 (Q2-3)	扉開放 (Q2-6)	追跡認知 (Q3-1)	追跡対峙 (Q3-2)	解放感 (Q3-3)	備考
A	2	3	5	6	3	5	後半恐怖上昇, 典型的パターン
B	6	5	5	7	4	2	全体的に高い恐怖度, 周囲の騒音言及
C	4	4	6	6	7	6	一貫して高い恐怖および緊張維持
D	2	2	3	3	1	1	「ゾンビ追跡気づかず」, 低い恐怖度
E	5	6	6	6	7	7	非常に高い恐怖反応および解放感
F	3	5	6	1	1	6	「追跡認知できず」, 特異なパターン

表 5.5 事後アンケート詳細結果（7点 Likert 尺度, 平均 ± SD）

質問 ID	評価項目 (イベント内容)	平均	SD
Q2-1	暗い屋敷の探索開始時の恐怖/不安	3.33	1.51
Q2-2	1 つ目のビーカー獲得時の恐怖/不安	2.83	1.17
Q2-3	2 つ目のビーカー獲得および BGM 変化時の緊張	4.17	1.47
Q2-4	3 つ目のビーカー獲得時の驚き	4.33	1.37
Q2-5	4 つ目のビーカー獲得直後の演出変化に対する恐怖	4.17	2.14
Q2-6	ゾンビ部屋のドアを初めて開けた瞬間の恐怖/緊張	5.50	1.38
Q3-1	ゾンビの追跡を認知した瞬間の恐怖/緊張	4.33	2.58
Q3-2	ゾンビが近くで停止した時の恐怖/緊張	4.50	2.52
Q3-3	実験終了時の緊張解放感の程度	4.00	2.00

5.1.8 全体統計

表 5.6 に全参加者（6 名, 8 セッション）の Phase 別生体反応統計量を示す。図 5.5 に示すように, Phase 0 から Phase 3 に向かって SCL および EMG の上昇傾向が確認された。

表 5.6 全参加者の Phase 別生体反応統計量（6 名, 8 セッション, Mean ± SD）

特徴量	Phase 0	Phase 1	Phase 2	Phase 3
心拍数 (bpm)	73.0 ± 11.7	74.2 ± 9.5	76.5 ± 8.1	72.2 ± 20.2
HRV RMSSD (ms)	143.3 ± 284.5	51.4 ± 32.7	67.0 ± 53.0	742.4 ± 1775.9
LF/HF 比	1.7 ± 1.1	2.4 ± 1.9	1.9 ± 1.3	1.6 ± 2.5
SCL (μS)	22.2 ± 6.2	20.9 ± 6.5	26.6 ± 3.0	26.7 ± 1.5
EMG Mean (μV)	14.9 ± 7.2	15.9 ± 8.4	19.8 ± 7.9	27.7 ± 17.4
EMG RMS (μV)	16.9 ± 6.6	18.2 ± 6.6	25.4 ± 8.9	36.0 ± 30.1

Mean Physiological Response by Phase (N=8, Mean $\pm$ SD)




図 5.5 Phase 別平均生体反応 (6 名, 8 セッション, Mean $\pm$ SD). Phase 2 から Phase 3 にかけて SCL および EMG の上昇が確認される。

Phase-wise Physiological Response Comparison (N=8)




図 5.6 Phase 別生体反応の箱ひげ図 (6 名, 8 セッション)。

5.1.9 個人差分析

図 5.7 および図 5.8 に参加者別の生体反応パターンを示す。Subject E1, E2 は Phase 3 で顕著な LF/HF 上昇を示し、Subject D は Phase 3 で EMG RMS の著しい増加を示した。一方、Subject A, F は Phase 全体を通じて比較的安定した反応パターンを示した。

Individual Subject Variation by Phase




図 5.7 参加者別 Phase 変動. Subject A-F (6 名, 8 セッション) の各 Phase 別生体反応. 個人差が大きいことが確認された.

Subject × Phase Heatmap




図 5.8 参加者 × Phase ヒートマップ。色が濃いほど値が高い。SCL は Phase 2-3 で全体的に上昇傾向を示す。

第 6 章 実験結果

6.1 主観的感情評価分析

実験直後に実施したアンケート結果を分析し、参加者の主観的な感情変化を定量化した。この分析結果は生体信号解釈の基準点（Ground Truth）として活用される。

6.1.1 被験者別反応の類型化および特異事例の分析

アンケート調査は、大きく分けて Phase 2 の探索パート（Q2-1 ~ Q2-6）と Phase 3 の追跡パート（Q3-1 ~ Q3-3）で構成された。参加者の回答を総合した結果、ゾンビがいる部屋のドアを開けた瞬間（Q2-6）およびゾンビが追跡を開始した時点（Q3-1）において、最も高い恐怖値が記録された。

主観報告に基づき、参加者の反応パターンを以下の 3 つのタイプに分類した。

1. 没入型恐怖反応群 (Immersion-Fear Group: A, B, C, E) このグループは、実験の進行に伴い恐怖値が線形に上昇する傾向を示した。特に参加者 E は、ゾンビ追跡状況（Q3-1, Q3-2）において最高値である 7 点を記録し、極度の恐怖と緊張を訴えた。彼らは VR 環境が提供する視聴覚刺激を現実的な脅威として受容しており、これは後述する生体信号の急激な変化とも一致する結果であった。

2. 認知失敗群 (Cognitive Failure Group: D, F) これは特定の状況を明確に認知できず、感情生起が抑制された事例である。参加者 D は、ゾンビが追跡している事実を認知できなかったと回答し、その結果 Q3-1 のスコアは 1 点にとどまった。参加者 F も同様の認知失敗を報告し、事後インタビューにおいて「Q3-1, Q3-2 の状況を認知できなかった」と明言した。これは、VR 内での感情変動が参加者の注意（Attention）および認知的評価（Cognitive Appraisal）プロセスに大きく依存することを示唆している。

3. 選択的知覚反応群 (Selective Perception Group: F) これは持続的な恐怖よりも瞬間的な驚き刺激に敏感に反応したケースである。参加者 F は、追跡状況は認知できなかったものの、ゾンビ部屋のドアを開けた瞬間（Q2-6）には 6 点という高い緊張度を報告した。これは、特定の演出が意図した感情を誘発することに成功したことを意味し、全体的なナラティブへの没入とは別に、瞬間的なインパクトが生体反応に影響を与えた可能性を示唆している。

6.2 客観的生体反応分析: フェーズ別統計および指標分析

6.2.1 皮膚電気活動 (EDA) 分析結果

皮膚電気活動 (Electrodermal Activity: EDA) は交感神経系の活性度を表す核心的な指標であり、本実験では皮膚コンダクタンスレベル (Skin Conductance Level: SCL) の平均値を中心に分析した。

データ分析の結果、Phase 0 と Phase 1 の間では有意な SCL の上昇は観察されなかったが、暗い屋敷を探索し始める Phase 2 に進入すると、SCL 平均値が $26.59 \mu\text{S}$ へと急激に上昇した。これは視覚的制限と環境音が参加者の警戒心 (Vigilance) を高め、交感神経系を持続的に覚醒させたことを意味する。Phase 3 でも

表 6.1 全参加者のフェーズ別 EDA (SCL) 統計値 (Mean $\pm$ SD)

フェーズ (Phase)	平均 SCL (μ S)	標準偏差 (SD)	最小値 (Min)	最大値 (Max)
Phase 0	22.20	6.22	9.05	28.02
Phase 1	20.90	6.51	7.55	28.09
Phase 2	26.59	2.99	19.42	28.20
Phase 3	26.67	1.47	23.94	27.82

26.67 μ S の高い水準が維持され、標準偏差が 1.47 μ S と非常に低く現れた点は、すべての参加者が共通して高い覚醒状態に到達したことを示している。特に SCR (Skin Conductance Response) ピーク数については、Phase 1 で平均 7.88 回であったものが、探索と追跡が含まれるシナリオにおいて持続的に発生し、脅威刺激に対する反応性を証明した。

6.2.2 心拍変動 (HRV) および心電図 (ECG) 分析結果

心電図データを基に算出された心拍数 (Heart Rate, HR) と心拍変動指標は、被験者の自律神経系バランスとストレスレベルを表す。

表 6.2 全参加者のフェーズ別 ECG/HRV 主要統計値 (Mean $\pm$ SD)

特徴量 (Feature)	Phase 0	Phase 1	Phase 2	Phase 3
平均心拍数 (HR, bpm)	73.02 $\pm$ 11.65	74.15 $\pm$ 9.54	76.52 $\pm$ 8.11	72.16 $\pm$ 20.23
RMSSD (ms)	143.34 $\pm$ 284.51	51.42 $\pm$ 32.71	67.04 $\pm$ 53.03	742.37 $\pm$ 1775.91
SDNN (ms)	126.01 $\pm$ 193.24	54.86 $\pm$ 32.56	68.30 $\pm$ 35.40	459.45 $\pm$ 1051.43
LF/HF 比	1.72 $\pm$ 1.10	2.37 $\pm$ 1.95	1.87 $\pm$ 1.26	1.58 $\pm$ 2.50

心拍数の場合、Phase 2 で平均 76.52 bpm とピークに達し、探索過程における持続的な緊張状態を反映した。興味深い点は、最も強力な恐怖刺激が提示された Phase 3 (Chase) において、平均心拍数が 72.16 bpm へとわずかに減少し、標準偏差が 20.23 bpm へと急激に増加した点である。これは、一部の被験者に見られた「すくみ反応 (Freezing Response)」によって心拍数が一時的に低下した事例と、逆にパニック状態で心拍数が急増した事例が混在して現れた結果であると解釈される。

時間領域 HRV 指標である RMSSD と SDNN は、Phase 1 においてベースラインと比較して大きく減少し、認知的負荷 (Cognitive Load) が副交感神経活動を抑制し、ストレス反応を誘導したことを定量的に示している。Phase 3 の RMSSD 値が異常に高く測定されたことは、一部の被験者の激しい不整脈様反応や身体動作によるアーティファクトが反映された結果と推定され、これは今後の分析において精密なノイズ除去の必要性を示唆している。

周波数領域の LF/HF 比は Phase 1 で 2.37 と最も高く、これは Go/No-Go 課題を遂行する過程における高度な集中と交感神経系の活性化を意味する。

6.2.3 筋電図 (EMG) 分析結果

右腕の筋肉に装着された EMG センサは、被験者の身体的緊張度と驚き反応に伴う筋肉収縮を測定した。

EMG 分析の結果、フェーズが進行するにつれて筋肉の緊張度が明確に上昇する様相が観察された。特に Phase 3 における RMS 電圧は 36.01 μ V であり、Baseline (16.87 μ V) と比較して 2 倍以上に増加し、最大電圧は平均 223.11 μ V に達した。これは、ゾンビの追跡という直接的な脅威の前で、被験者が逃避あるいは防

表 6.3 全参加者のフェーズ別 EMG 主要統計値 (Mean $\pm$ SD)

特徴量 (Feature)	Phase 0	Phase 1	Phase 2	Phase 3
平均電圧 (Mean, μ V)	14.90 $\pm$ 7.17	15.95 $\pm$ 8.36	19.83 $\pm$ 7.94	27.69 $\pm$ 17.36
RMS 電圧 (RMS, μ V)	16.87 $\pm$ 6.63	18.23 $\pm$ 6.61	25.40 $\pm$ 8.93	36.01 $\pm$ 30.05
最大電圧 (Max, μ V)	81.86 $\pm$ 60.27	104.03 $\pm$ 66.30	228.27 $\pm$ 190.88	223.11 $\pm$ 302.27

御のために身体筋肉を強く収縮させたことを示す決定的な証拠である。また、標準偏差が 30.05 μ V と非常に大きく現れた点は、被験者の傾向によって身体的硬直反応の程度が極端に分かれたことを示唆している。

6.3 個人差分析および特異反応者の識別：主観・客観連携の深層事例

全体統計分析を超え、主観的報告と生体反応の間の相関関係を明確に把握するため、主要な被験者 3 名に対する深層事例分析を遂行した。

6.3.1 極端的反応者 (Subject E2)

参加者 E2 は、アンケートにおいて追跡時の恐怖度 7 点と解放感 7 点を同時に記録した「超没入型」参加者である。彼の生体データは、このような主観的報告を劇的に裏付けている。

Phase 3 において EMG RMS 値が 101.99 μ V へと急増したが、これは全被験者平均の約 3 倍に達する数値である。同時に心拍数は 29.00 bpm と異常に低く測定されたが、これは心拍変動 (RMSSD 4766.04 ms) の極端な上昇と結合しており、単純な安静ではなく、極度のストレスによる心臓調節能力の一時的麻痺、あるいは強力な「すくみ反応 (Freezing Response)」による徐脈現象として解釈される。主観的にも最も高い恐怖度 (7 点) を報告しており、客観的生体信号と主観的経験が最も強力に一致するパターンを示した。

6.3.2 認知失敗および低反応者 (Subject D)

参加者 D は、主観的に追跡を認知できなかったと報告しており、これは生体指標の停滞につながった。

- **SCL 減少:** Phase 2 (28.20 μ S) から Phase 3 (23.94 μ S) へと覚醒数値が下落した。
- **安定的 HR:** 心拍数もまた 77.77 bpm から 78.65 bpm へとほとんど変化がなかった。

これは「実験課題が無事に終了した」と判断し、急激な心理的弛緩 (Early Relief) 状態に進入したことを示唆する。このようなベースライン以下への生体指標の下落は、感情推定フレームワークが単に恐怖の有無だけでなく、ユーザが現在の状況を「安全」あるいは「終了」と認知しているか否かを判別する有用な指標となり得ることを示している。

6.3.3 無意識的緊張維持者 (Subject F)

参加者 F は事後アンケートにおいて追跡を認知できなかったと回答したが、彼の身体は異なる反応を示していた。

- **高い覚醒水準:** Phase 3 の SCL 値は 25.32 μ S であり、全参加者の Phase 3 平均である 26.67 μ S に近接した数値である。心拍数は 90.39 bpm で実験全体の中で最高値を記録し、EMG RMS もまた 35.17 μ V で平均以上の高い身体的緊張度を示した。

- **SCR ピークの存在:** 特に Phase 2 において 16 回の SCR ピークが発生したが、これは彼がアイテムを収集する過程ですでに相当な心理的圧迫を感じていたことを意味する。

「追跡を認知できなかった」という回答は、実際の追跡状況における視覚的認知失敗を意味するだけであり、彼が置かれていた環境全体に対する緊張感は解消されていなかったことを示唆する。

6.4 機械学習による自動 Phase 分類

生体信号特徴量のみを用いて実験 Phase を自動分類する機械学習モデルを構築し、その性能を評価した。

6.4.1 手法

6.4.1.1 特徴量

表 6.4 に示す 20 個の生理学的特徴量を使用した。

表 6.4 機械学習に使用した特徴量

信号種別	特徴量
ECG	心拍数, HRV (RMSSD, SDNN, pNN50), LF/HF 比, R-peak 数, RR 間隔統計
EMG	平均値, 標準偏差, 最大値, RMS, 積分 EMG
EDA	平均 SCL, SCL 標準偏差, 平均 SCR, 最大 SCR, SCR ピーク数

6.4.1.2 交差検証

一般化性能を評価するため、Leave-One-Session-Out 交差検証を採用した。本実験では 6 名の参加者から 8 セッションのデータを収集した（2 名が 2 回参加）。各 fold（計 8 回）では 1 セッションをテストセット、残り 7 セッションをトレーニングセットとして使用した。

なお、同一参加者の複数セッション（Subject B: 2 セッション, Subject E: 2 セッション）がトレーニングとテストに分かれる場合があるため、本評価は厳密な個人間一般化性能ではなく、新規セッションへの汎化性能を示している。

6.4.1.3 分類アルゴリズム

5 種類の機械学習アルゴリズムを比較評価した：Random Forest, Gradient Boosting, SVM (RBF kernel), k-NN, Logistic Regression。

6.4.2 分類結果

6.4.2.1 モデル比較

表 6.5 に各モデルの LOSO 交差検証による性能を示す。

Random Forest が最高性能（Accuracy: 67.7%, F1: 66.6%）を達成した。図 6.1 に各モデルの性能比較を示す。

表 6.5 Phase 分類モデルの性能比較 (LOSO 交差検証)				
モデル	Accuracy	F1-Score	Precision	Recall
Random Forest	0.677	0.666	0.704	0.677
Gradient Boosting	0.645	0.637	0.655	0.645
SVM (RBF)	0.452	0.465	0.507	0.452
k-NN	0.452	0.421	0.449	0.452
Logistic Regression	0.484	0.495	0.516	0.484




図 6.1 Phase 分類モデルの性能比較. Random Forest と Gradient Boosting が他モデルを上回る性能を示した.

6.4.2.2 混同行列分析

図 6.2 に Random Forest モデルの混同行列を示す。




図 6.2 各モデルの正規化混同行列。Random Forest では Phase 0 (BASELINE) が 88%, Phase 3 (CHASE) が 71%の再現率を示した。

Phase 別の分類性能は以下の通りである：

- **Phase 0 (BASELINE):** Recall 88%, 安定した生体信号パターンにより高い識別率
- **Phase 1 (TASK):** Recall 38%, Phase 0 との混同が多く、認知課題による生理的変化が限定的
- **Phase 2 (PUZZLE):** Recall 75%, 探索活動に伴う EMG・EDA 上昇が特徴的
- **Phase 3 (CHASE):** Recall 71%, 恐怖反応による顕著な生理的変化を捕捉

6.4.2.3 特徴量重要度

図 6.3 に Random Forest モデルにおける特徴量重要度を示す。

上位 5 特徴量は以下の通りである：

1. **ECG_num_r_peaks** (16.1%): Phase 持続時間と関連
2. **EMG_integrated_emg** (9.3%): 累積筋活動量
3. **EMG_std_uV** (8.0%): 筋活動の変動性
4. **EDA_mean_SCL_uS** (7.2%): 平均皮膚電気伝導度
5. **EDA_mean_SCR_uS** (5.8%): 平均皮膚電気反応




図 6.3 Random Forest モデルの特徴量重要度. ECG_num_r_peaks (R-peak 数), EMG_integrated_emg (積分 EMG), EMG_std_uV (EMG 標準偏差) が上位を占めた.

6.4.2.4 参加者別分類精度

図 6.4 に参加者別の分類精度を示す.

参加者間で大きな精度差が観察された (33%–100%). この結果は, 個人差を考慮したキャリブレーションの必要性を示唆している.




図 6.4 参加者別 Phase 分類精度. Subject B2, E2 は 100%の精度を達成した一方, Subject A は 33%と低精度であった.

第7章 考察

7.1 実験結果の解釈および生体信号の反応

本研究で構築した感情推定フレームワークは、VR 環境においてユーザが感じる感情変化をリアルタイムに捕捉することを目的としている。実験設計に従って進行された4段階のフェーズ (Phase 0-3) を通じて、ユーザの心理状態が安定した状態から恐怖状態へと段階的に変化することが確認され、これは収集された生体データによって裏付けられた。特に皮膚電気活動 (EDA)、心電図 (ECG)、筋電図 (EMG) を統合的に分析することで、個別の信号のみでは把握が困難なユーザの内面状態をより立体的に理解することが可能となった。

データを具体的に見ると、皮膚コンダクタンスレベル (SCL) は探索が開始される Phase 2 において前段階よりも大きく上昇して約 26.59 μ S を記録し、ゾンビが出現する Phase 3 まで高い水準を維持した。これは、VR の視覚的制限と音響効果がユーザの緊張感を効果的に高めたことを示している。特に Phase 3 においてすべての参加者の SCL 値が一様に高く現れた点は、この段階で共通して強い覚醒状態を経験したことを示唆する。

一方で心拍数 (HR) は少し異なる様相を示した。Phase 2 までは漸進的に上昇したが、最も恐ろしい刺激が与えられる Phase 3 において、むしろ平均値が 72.16 bpm へと低下しつつ参加者ごとの偏差が大きくなった。これは単に平均心拍数のみで感情を判断することが困難であることを示しており、「すくみ (Freezing) 反応」のような個人ごとの対応方式の差異が反映された結果であると考えられる。

7.2 参加者別特異反応とすくみ (Freezing) 現象

本実験で注目すべき部分は、参加者ごとに現れた反応の差異である。特に参加者 E2 の事例が印象的である。E2 はアンケートにおいてゾンビ追跡状況に対して満点である 7 点の恐怖を感じたと回答した。しかし実際の生体データでは、Phase 3 の心拍数が 28.96 bpm まで低下する非正常な徐脈現象が現れ、心拍変動指標 (RMSSD) は非常に高く測定された。

これは心理学で言われる「恐怖誘発性徐脈 (Fear-induced Bradycardia)」、すなわちすくみ反応の典型的な姿である。脅威を感じた際に身体の動きを止めて周囲に集中する防御機制が作動したものであり、この時、副交感神経が強く活性化されながら心拍数が急激に低下することになる。E2 の筋電図 (EMG) 値が平均より 3 倍も高かった点を考慮すれば、外見上は動いていなかったが、体内では極度に緊張し筋肉を収縮させていたことが分かる。

参加者 D と F の事例も興味深い。D はゾンビが追いかけてきていることに気づかず恐怖点数として 1 点のみを与え、生体データでも緊張が解ける様子が現れた。一方で F は本人も追跡を認知できなかったと回答したが、実際の身体反応 (SCL, HR, EMG) は全体平均よりも高いか同等の水準を維持した。これは意識的には脅威を知らなかったとしても、VR 環境の全般的な雰囲気のために無意識的な緊張状態が継続していたことを示している。

7.3 機械学習基盤フェーズ分類の意義および特徴量分析

機械学習モデルを通じて実験フェーズを自動的に分類した結果、ランダムフォレスト (Random Forest) モデルが 67.7% の精度を記録した。これは 4 つの状態を分類する問題において無作為確率 (25%) よりも約 2.7 倍高い性能である。このような結果は、センサから抽出された生理的特徴量が VR 体験中の心理状態変化を有意に反映していることを立証する。特に安定状態 (Phase 0) と追跡状態 (Phase 3) の識別率が高く現れたが、これは恐怖状況で発生する生体反応の明確な変化をモデルが効果的に捕捉できることを意味する。

特徴量重要度を分析してみると、筋電図 (積分 EMG, 標準偏差) と皮膚コンダクタンス (平均 SCL, 平均 SCR) がフェーズ識別に非常に有効な役割を果たした。これらの指標は恐怖と緊張状態で発生する交感神経系の活性化をよく示しており、今後のリアルタイム感情認識システムにおいても核心的な役割を果たすことが期待される。

ただし、心電図の R-peak 数 (ECG_num_r_peaks) が最も重要な指標として選ばれた点は注意が必要である。これは実験設計上、フェーズごとの持続時間が異なっていた点 (Phase 2 は長く、Phase 3 は短い) がモデル学習に反映された「持続時間バイアス (Duration bias)」である可能性が高い。したがって、真の意味での感情認識のためには、特徴量を単位時間当たりの比率として正規化する過程が必須的に伴わなければならない。

7.4 リアルタイム感情認識システム高度化のための展望

本研究で構築した分類モデルは、リアルタイム感情認識フレームワークへと進むための予備検証段階である。実際のサービスで活用可能な水準のシステムを構築するためには、次のような課題を解決しなければならない。

第一に、学習ラベルの再定義が必要である。現在は実験段階 (文脈情報) を分類対象としたが、実用的なシステムのためには、ユーザが直接報告した主観的感情スコア (恐怖度、緊張度など) を分類目標としなければならない。アンケート結果を活用して「高恐怖状態」と「低恐怖状態」などに感情ラベルを細分化して再学習させれば、モデルの実用性がさらに高まるであろう。

第二に、時間分解能の改善である。本研究では数十秒から分単位のフェーズ分類を遂行したが、リアルタイムコンテンツに応用するには秒単位の精密な推定が必要である。このためにスライディングウィンドウ (Sliding Window) 方式を導入し、連続的に感情状態を推定する手法が必要である。

第三に、個人適応型メカニズムの導入である。参加者ごとに精度偏差 (33% ~ 100%) が大きく現れたことは、個人ごとの生理的特性の差異を示している。実用システムでは、体験前の短いキャリブレーション (Calibration) セッションを通じて個人の基底反応を学習し、これを基にモデルを補正する機能が非常に重要である。

7.5 技術的限界および改善方向

システム実装において最も大きな技術的課題は、動きによるノイズ (Motion Artifact) とデータ同期化問題であった。ユーザが VR 機器を装着して激しく動く過程で、心電図信号が揺れたり筋電図信号に雑音が混ざる現象が発生した。

特に Phase 3 で現れた一部の数値は、実際の反応だけでなくセンサの揺れによるエラーが混ざった可能性を排除し難い。これを改善するために、加速度計データを参照信号として活用し、動きノイズをリアルタイムに除去する技術を導入しなければならない。また、Unity と Python サーバ間の非同期通信遅延を減らすために、LSL (Lab Streaming Layer) のような専門的な同期プロトコルを適用することも考慮に値する。

第 8 章 結論

本研究では、VR 体験中の感情状態を没入感を損なうことなく客観的に扱うために、生体信号（EDA, ECG, EMG）と VR 内のイベント／行動ログをリアルタイムに同期・記録できるマルチモーダル感情推定フレームワークを構築した。予備実験の結果、恐怖・緊張が高まる場面で EDA/EMG に一貫した変化が観察され、Phase 分類においても無作為水準を上回る性能が得られたことから、提案フレームワークが VR 体験の客観的評価に有用である可能性を示した。

一方で、被験者数・セッション数の不足や動作由来ノイズの影響により、心拍系指標の安定性と個人間一般化には課題が残る。今後はデータ規模の拡大とアーティファクト除去の強化に加え、分類対象を Phase から主観評定に基づく感情ラベル（高恐怖、低恐怖等）へ再定義し、スライディングウィンドウによる秒単位推定と個人キャリブレーションを組み合わせ、実運用可能なリアルタイム感情推定へ発展させる。

謝 辞

本研究を進めるにあたり，終始懇切丁寧なご指導とご鞭撻を賜りました関西学院大学工学部知能・機械工学課程 井村誠孝教授に，謹んで深甚なる謝意を表します．また，本研究の遂行に際し，実験にご協力賜りました被験者の皆様には，貴重なお時間を割いてご参加いただき，多大なるご協力を賜りましたことをここに記し，深く感謝申し上げます．

参考文献

- [1] Javier Marín-Morales, Carmen Llinares, Jaime Guixeres, and Mariano Alcañiz. Emotion recognition in immersive virtual reality: From statistics to affective computing. *Sensors*, Vol. 20, No. 18, p. 5163, 2020.
- [2] C. E. Orozco-Mora, R. Q. Fuentes-Aguilar, and G. Hernández-Melgarejo. Dynamic difficulty adaptation based on stress detection for a virtual reality video game: A pilot study. *Electronics*, Vol. 13, No. 12, p. 2324, 2024.
- [3] L. Shu, J. Xie, M. Yang, Z. Li, Z. Li, D. Liao, X. Xu, and X. Yang. A review of emotion recognition using physiological signals. *Sensors*, Vol. 18, No. 7, p. 2074, 2018.
- [4] D. Liao, L. Shu, G. Liang, Y. Li, et al. Design and evaluation of affective virtual reality system based on multimodal physiological signals and self-assessment manikin. *IEEE Journal of Electromagnetics, RF and Microwaves in Medicine and Biology*, Vol. 4, No. 3, pp. 216–223, 2020.
- [5] M. N. Dar, M. U. Akram, S. G. Khawaja, and A. N. Pujari. Cnn and lstm-based emotion charting using physiological signals. *Sensors*, Vol. 20, No. 16, p. 4551, 2020.
- [6] L. B. Hinkle, K. K. Roudposhti, and V. Metsis. Physiological measurement for emotion recognition in virtual reality. In *2019 2nd International Conference on Data Intelligence and Security (ICDIS)*, pp. 136–143, 2019.
- [7] D. Pajić, S. Sadiković, M. Oljača, et al. Risky behavior in virtual reality: The roles of personality, environment, and physiology. *PLoS ONE*, Vol. 20, No. 1, p. e0316896, 2025.
- [8] J. H. T. Lin. Fear in virtual reality (vr): Fear elements, coping reactions, immediate and next-day fright responses toward a survival horror zombie virtual reality game. *Computers in Human Behavior*, Vol. 72, pp. 350–361, 2017.
- [9] Y. Çimtay, E. Ekmekcioglu, and S. Çağlar Özhan. Cross-subject multimodal emotion recognition based on hybrid fusion. *IEEE Access*, Vol. 8, pp. 168865–168875, 2020.
- [10] J. Marín-Morales, J. L. Higuera-Trujillo, A. Greco, J. Guixeres, C. Llinares, E. P. Scilingo, M. Alcañiz, and G. Valenza. Affective computing in virtual reality: Emotion recognition from brain and heartbeat dynamics using wearable sensors. *Scientific Reports*, Vol. 8, No. 1, p. 13657, 2018.
- [11] E. E. Arslan, M. F. Akşahin, M. Yilmaz, and H. E. Ilgın. Towards emotionally intelligent virtual environments: Classifying emotions through a biosignal-based approach. *Applied Sciences*, Vol. 14, No. 19, p. 8769, 2024.
- [12] N. Dozio, et al. A design methodology for affective virtual reality. *International Journal of Human-Computer Studies*, Vol. 162, p. 102791, 2022.
- [13] Radiah Rivu, Paula Prodan, Ville Mäkelä, Pascal Knierim, and Florian Alt. How are your participants feeling today? accounting for and assessing emotions in virtual reality. In *MuC '23: Proceedings of Mensch und Computer 2023*, pp. 37–48, 2023.
- [14] Mathias Benedek and Christian Kaernbach. A continuous measure of phasic electrodermal activity. *Journal of Neuroscience Methods*, Vol. 190, No. 1, pp. 80–91, 2010.

- [15] Jason J. Braithwaite, Derrick G. Watson, Robert Jones, and Mickey Rowe. A guide for analysing electrodermal activity (eda) & skin conductance responses (scrs) for psychological experiments. Technical report, University of Birmingham, 2013.
- [16] Sylvia D. Kreibig. Autonomic nervous system activity in emotion: A review. *Biological Psychology*, Vol. 84, No. 3, pp. 394–421, 2010.

付録

A 本文と直接関係ない知識

付録は無いことが多いが、どうしても書いておきたいことは書いてもよい。無い場合は、\appendix からまとめて削除する。